



**Universidad
Zaragoza**

Trabajo Fin de Grado

Predicción de fibrilación auricular paroxística a partir
del electrocardiograma en ritmo sinusal mediante el
análisis con redes neuronales profundas

*Prediction of Paroxysmal Atrial Fibrillation from the
Sinus Rhythm Electrocardiogram Using Deep Neural
Networks*

Autor

Diego Bouchet Agudo

Directores

Juan Pablo Martínez Cortés

Antonio Miguel Artiaga

Titulación

Grado en Ingeniería de Tecnologías y Servicios de Telecomunicación

Escuela de Ingeniería y Arquitectura (EINA)

2026

Resumen

Título del trabajo

Predicción de fibrilación auricular paroxística a partir del electrocardiograma en ritmo sinusal mediante el análisis con redes neuronales profundas

English Title

Prediction of Paroxysmal Atrial Fibrillation from the Sinus Rhythm Electrocardiogram Using Deep Neural Networks

RESUMEN

La Fibrilación Auricular Paroxística (PAF) es una de las arritmias más comunes, caracterizada por latidos irregulares en la aurícula. Debido a su naturaleza intermitente que la caracteriza, su diagnóstico temprano es complejo, es por ello que la predicción de dichos episodios a partir de señales ECG en ritmo sinusal es de especial interés. En este trabajo, se ha abordado este desafío.

Una de las limitaciones que suelen tener trabajos de este tipo es la falta de generalización de los modelos, ya que si son entrenados en una base de datos específica, de unas características concretas, no suelen generalizar bien a otras bases de datos. En este trabajo, se han consolidado cinco bases de datos públicas de PhysioNet para abordar esta limitación.

Se ha diseñado un preprocesamiento que extrae ventanas inmediatamente anteriores al inicio de un episodio de fibrilación auricular, y se extraen nueve variables de variabilidad del ritmo cardíaco (HRV). Se han implementado cuatro arquitecturas distintas de redes neuronales: ResNet 1D (baseline), SEResNet 1D (con atención de canales), un híbrido CNN-Transformer y Mamba 1D (*selective state space model*). Para evitar la filtración de datos, se hizo validación cruzada, agrupando estrictamente por sujeto (5-Fold GroupKFold).

Este trabajo estudia la viabilidad de un sistema generalizable inter-sujeto para la monitorización de alerta temprana de episodios de Fibrilación Auricular Paroxística.

Palabras clave: Fibrilación Auricular Paroxística, Predicción Inminente, Procesamiento de ECG, Aprendizaje Profundo, Variabilidad del Ritmo Cardíaco (HRV), Mamba.

ABSTRACT

Paroxysmal Atrial Fibrillation (PAF) is one of the most common arrhythmias, characterized by irregular heartbeats in the atrium. Due to its intermittent nature that characterizes it, its early diagnosis is complex; that is why the prediction of such episodes from ECG signals in sinus rhythm is of special interest. In this work, this challenge has been addressed.

One of the limitations that works of this type usually have is the lack of generalization of the models, since if they are trained on a specific database, with concrete characteristics, they do not usually generalize well to other databases. In this work, five public databases from PhysioNet have been consolidated to address this limitation.

A preprocessing has been designed that extracts windows immediately prior to the onset of an atrial fibrillation episode, and nine heart rate variability (HRV) variables are extracted. Four different neural network architectures have been implemented: 1D ResNet (baseline), 1D SEResNet (with channel attention), a hybrid CNN-Transformer, and 1D Mamba (*selective state space model*). To avoid data leakage, cross-validation was performed, grouping strictly by subject (5-Fold GroupKFold).

This work studies the feasibility of an inter-subject generalizable system for early-warning monitoring of Paroxysmal Atrial Fibrillation episodes.

Keywords: Paroxysmal Atrial Fibrillation, Imminent Prediction, ECG Signal Processing, Deep Learning, Heart Rate Variability (HRV), Mamba.

Índice general

Resumen	I
1 Introducción	1
1.0.1 Fundamentos de la Electrocardiografía (ECG)	1
1.1 Contexto del Trabajo	2
1.2 Objetivos del Proyecto	3
2 Datos	4
2.1 Bases de datos utilizadas	4
2.1.1 PAF Prediction Challenge Database (afpdb)	4
2.1.2 China Physiological Signal Challenge 2021 (cpssc2021)	4
2.1.3 Long-Term Atrial Fibrillation Database (ltafdb)	4
2.1.4 Smart Health Devices - Atrial Fibrillation Database (shdb-af)	5
2.1.5 MIT-BIH Atrial Fibrillation Database (afdb)	5
2.2 Características comparativas de los conjuntos de datos	5
3 Metodología	6
3.1 Descarga y lectura de bases de datos	6
3.2 Preprocesamiento	6
3.3 Extracción de Ventanas y Prevención de Data Leakage	7
3.4 Aumento de Datos (Data Augmentation)	7
3.5 Extracción de Variabilidad del Ritmo Cardíaco (HRV)	8
3.6 Arquitecturas de Aprendizaje Profundo	10
3.6.1 ResNet 1D (Baseline)	10
3.6.2 SEResNet 1D (Atención de Canales)	11
3.6.3 CNN-Transformer Híbrido	11
3.6.4 Mamba 1D (Modelo de Espacio de Estados)	11
3.6.5 Integración de Características HRV	11
3.7 Estrategia de Evaluación y Validación Cruzada	11
4 Resultados y Discusión	12
4.1 Resultados detallados por arquitectura	12
4.1.1 Arquitectura ResNet 1D	12
4.1.2 Arquitectura SEResNet 1D con atención de canales	13
4.1.3 Arquitectura CNN-Transformer Híbrida y variaciones estructurales	14
4.1.4 Arquitectura Mamba 1D y capacidad de representación	15
4.2 Evaluación comparativa inter-modelo	15

4.3	Análisis de resultados y discusión	16
4.3.1	Discrepancia entre el rendimiento en test general y el benchmark de PhysioNet .	16
4.3.2	Estudio de la contribución de la variabilidad del ritmo cardíaco (HRV)	17
4.4	Comparación con trabajos relacionados	18
5	Conclusiones y Líneas Futuras	19
5.1	Resumen y aportaciones del proyecto	19
5.2	Cumplimiento de objetivos	19
5.3	Valoración crítica y limitaciones	20
5.4	Líneas futuras	20
	Referencias	21
	Anexos	22
A	Detalle de las Arquitecturas de Aprendizaje Profundo	23
A.1	ResNet 1D	23
A.2	SEResNet 1D	23
A.3	CNN-Transformer Híbrido	24
A.4	Mamba 1D	25

Índice de figuras

1.1	Orientación espacial de las derivaciones ECG. Imagen obtenida de Wikipedia.	1
1.2	Ejemplo de ECG en fibrilación auricular. Imagen obtenida de la Mayo Clinic.	2
2.1	Distribución de segmentos de 5 minutos extraídos por clase y base de datos	5
3.1	Efecto del aumento de datos sobre un segmento de ECG de 4 segundos. Se muestra (a) la señal original normalizada, (b) la adición de deriva lenta (baseline wander), (c) la adición de ruido de alta frecuencia, y (d) el resultado combinado de todas las transformaciones.	9
A.1	Arquitectura base ResNet 1D. La red procesa la entrada reduciendo progresivamente la dimensión temporal mediante bloques residuales, integrando finalmente las características HRV antes del clasificador <i>fully connected</i>	24
A.2	Módulo Squeeze-and-Excitation. Tras cada bloque residual se incorpora este módulo que recalibra adaptativamente los pesos de los canales. Obtenida del paper original [10] . . .	24
A.3	Arquitectura SEResNet 1D. Tras cada bloque residual se incorpora un módulo Squeeze-and-Excitation que recalibra adaptativamente los pesos de los canales de extracción de características.	25
A.4	Arquitectura híbrida CNN-Transformer. Se utiliza un <i>frontend</i> convolucional para la extracción local y reducción de dimensionalidad, seguido de codificadores posicionales y un <i>Transformer Encoder</i> para la atención global.	26
A.5	Estructura interna del bloque Mamba. Se detalla el mecanismo del modelo de espacio de estados selectivo (SSM), donde los parámetros de discretización y transición se calculan de manera dinámica en función de la secuencia de entrada.	27
A.6	Arquitectura híbrida CNN-Mamba. La secuencia latente generada por el <i>frontend</i> convolucional es procesada de forma puramente secuencial mediante bloques SSM selectivos, prescindiendo de codificadores posicionales.	27

Índice de cuadros

2.1	Resumen comparativo de las 5 bases de datos de estudio	5
4.1	Resultados de las variaciones de la arquitectura ResNet 1D con y sin aumento de datos .	13
4.2	Resultados de las variaciones de la arquitectura SEResNet 1D con y sin aumento de datos	14
4.3	Resultados de las variaciones de la arquitectura CNN-Transformer 1D con y sin aumento de datos	15
4.4	Resultados del rendimiento de las mejores variantes de cada arquitectura (seleccionadas según su F1 en validación) en validación y test	16
4.5	Resultados del estudio de contribución de HRV frente al modelo híbrido completo . . .	17

Capítulo 1

Introducción

1.0.1 Fundamentos de la Electrocardiografía (ECG)

Un electrocardiograma (ECG) es una representación gráfica de la actividad eléctrica del corazón en función del tiempo. Debido a que en cada latido se produce una despolarización y una repolarización de las células, se generan potenciales eléctricos que pueden ser detectados desde la superficie del cuerpo.

Para capturar esta señal, se colocan electrodos sobre la superficie del cuerpo del paciente, en puntos específicos, capaces de medir la diferencia de potencial eléctrico generada por este latido.

La combinación de estos electrodos da lugar a las *derivaciones*. En la práctica, se suele utilizar el sistema de 12 derivaciones, el cual se divide en:

- **Derivaciones bipolares (I, II, III):** Miden la diferencia de potencial entre dos extremidades (siguiendo el triángulo de Einthoven).
- **Derivaciones monopoles aumentadas (aVR, aVL, aVF):** Miden el potencial en una extremidad respecto a un punto de referencia central.
- **Derivaciones precordiales (V1 a V6):** Situadas directamente sobre el tórax para observar la actividad eléctrica en el plano horizontal del corazón.




Figura 1.1: Orientación espacial de las derivaciones ECG. Imagen obtenida de [Wikipedia](#).

Cada derivación observa el mismo fenómeno eléctrico, pero desde un ángulo espacial distinto. Esto resulta clave para la detección de patologías como arritmias o infartos. [1]

La Fibrilación Auricular (FA) es la arritmia cardíaca más común, caracterizada por un comportamiento auricular caótico (como se ilustra en la Figura 1.2). Esta patología provoca una pérdida de la contracción auricular efectiva, lo que incrementa el riesgo de formación de trombos, accidentes cerebrovasculares (ictus), insuficiencia cardíaca y deterioro cognitivo a largo plazo [2].




Figura 1.2: Ejemplo de ECG en fibrilación auricular. Imagen obtenida de la [Mayo Clinic](#).

Dentro de sus variantes, se encuentra la Fibrilación Auricular Paroxística (PAF, por sus siglas en inglés, *Paroxysmal Atrial Fibrillation*). Ésta se caracteriza por episodios esporádicos de arritmia, que se inician de manera espontánea y que vuelven al ritmo sinusal en un periodo de unos 7 días, aunque la mayoría lo hacen en menos de 24 horas.

Debido a esta naturaleza intermitente, los ECGs de corta duración no suelen capturarlos. Por ello, la predicción inminente de estos episodios, es decir, tener la capacidad de predecir si un paciente sufrirá un episodio en los próximos minutos a partir de su ritmo sinusal, en holters de larga duración es de especial interés.

Predecir un episodio con una ventana de antelación de hasta 5 minutos permitiría alertar al paciente para que cese actividades de riesgo, automatizar la administración preventiva de fármacos antiarrítmicos o preparar dispositivos de estimulación eléctrica cardíaca adaptativa.

Sin embargo, la predicción es una tarea compleja. La fase previa al episodio arritmico es en ritmo sinusal, por lo que a simple vista en el ECG no se observan patrones o anomalías morfológicas evidentes.

1.1 Contexto del Trabajo

Clasicamente este problema solía abordarse mediante la extracción de características de variabilidad del ritmo cardíaco (HRV, *Heart Rate Variability*) y por un clasificador lineal. Sin embargo esta estrategia no suele ser capaz de analizar las distorsiones morfológicas locales de las señales de ECG (como cambios

finos en la onda P o en el intervalo PR) que preceden a la FA.

Las redes neuronales cambian la forma de abordar este problema, permitiendo extraer información directamente de la señal ECG sin procesar. No obstante hay que tener en cuenta algunas limitaciones como:

1. **Sesgo de Base de Datos:** Se entrenan utilizando una única base de datos. Esto genera modelos altamente sobreajustados a las condiciones de ruido y hardware de esa base de datos concreta, que fracasan al ser validados en registros independientes.
2. **Data Leakage y validaciones débiles:** Con frecuencia se comparten ventanas del mismo paciente entre los conjuntos de entrenamiento y test, reportando precisiones artificialmente altas.

Este trabajo se enfoca en resolver estas limitaciones utilizando un dataset procedente de distintas bases de datos, evaluando los modelos mediante una validación cruzada inter-sujeto.

1.2 Objetivos del Proyecto

El objetivo de este proyecto es **diseñar, implementar y evaluar un sistema capaz de predecir de forma inminente (en una ventana de 5 minutos antes del inicio) episodios de Fibrilación Auricular Paroxística (PAF) a partir de segmentos de 1 minuto de señal ECG en ritmo sinusal.**

Para alcanzar este fin, se definen los siguientes objetivos:

- **Objetivo 1:** Integrar cinco bases de datos heterogéneas de PhysioNet: *afpdb*, *cpsec2021*, *ltafdb*, *shdb-af* y *afdb*.
- **Objetivo 2:** Desarrollar un pipeline de preprocesamiento que permita la extracción de ventanas variables de ritmo sinusal Pre-PAF y de características temporales y frecuenciales de HRV.
- **Objetivo 3:** Entrenar distintas arquitecturas de redes neuronales como: ResNet 1D (modelo base residual), SEResNet 1D (con atención por canal Squeeze-and-Excitation), un modelo CNN-Transformer (*multi-head self attention*) y Mamba 1D (basado en *state space models*).
- **Objetivo 4:** Integrar la información de HRV mediante una cabeza clasificatoria (Multi-Layer Perceptron) que potencie la toma de decisiones de las redes.
- **Objetivo 5:** Evaluar rigurosamente los modelos bajo un diseño GroupKFold para mitigar la filtración de datos.

Capítulo 2

Datos

La adquisición de datos de calidad es fundamental para el desarrollo de modelos capaces de predecir con generalidad y fiabilidad. Por ello se han incorporado varias bases de datos obtenidas de fuentes públicas, en concreto, de los repositorios de PhysioNet. Estas bases de datos contienen registros de electrocardiogramas (ECG) con anotaciones sobre episodios de fibrilación auricular paroxística (PAF).

2.1 Bases de datos utilizadas

Para el desarrollo de este proyecto se han empleado 5 bases de datos que se detallan a continuación:

2.1.1 PAF Prediction Challenge Database (afpdb)

Esta base de datos [3] fue diseñada para el PhysioNet Challenge de predicción de Fibrilación Auricular Paroxística. Contiene registros de ECG de dos canales con una duración de 30 minutos y una frecuencia de muestreo de 128 Hz. El conjunto de aprendizaje consta de 50 parejas de registros (100 registros en total) procedentes de 48 sujetos:

- **Registros tipo 'n':** 50 registros procedentes de sujetos sanos o sin antecedentes de Fibrilación Auricular.
- **Registros tipo 'p':** 50 registros obtenidos inmediatamente antes de un episodio de Fibrilación Auricular (Pre-PAF).

Adicionalmente, existe un conjunto de test con otros 100 registros procedentes de 50 sujetos, que se utilizará para compararse con otros trabajos publicados.

2.1.2 China Physiological Signal Challenge 2021 (cpssc2021)

Esta base de datos [4] contiene 1425 registros de 105 sujetos, dos canales, muestreadas a 200 Hz. Contiene anotaciones de ritmo, en concreto, de inicio y fin de episodios de Fibrilación Auricular.

2.1.3 Long-Term Atrial Fibrillation Database (ltafdb)

Esta base de datos [5] contiene registros de ECG ambulatorio de larga duración (aproximadamente 24 horas por registro), grabados a una frecuencia de muestreo de 128 Hz. Consta de 84 registros de 84 sujetos con fibrilación auricular paroxística o sostenida.

2.1.4 Smart Health Devices - Atrial Fibrillation Database (shdb-af)

Esta base de datos [6] proporciona señales de ECG de dos canales registradas mediante dispositivos wearables en condiciones cotidianas. Consta de 128 registros de larga duración (24 horas) procedentes de 122 sujetos con PAF, muestreados originalmente a 125 Hz y resampleados a 200 Hz. Nos proporciona la asignación entre señal y sujeto para prevenir filtraciones (leakage)

2.1.5 MIT-BIH Atrial Fibrillation Database (afdb)

Esta base de datos [7] consta de 25 registros de ECG de dos canales con una duración de 10 horas cada uno, grabados a 250 Hz. Cabe destacar que de 25, 23 de estos registros contienen señales de ECG utilizables, ya que los otros 2 constan únicamente de anotaciones.

2.2 Características comparativas de los conjuntos de datos

A continuación se presenta una tabla 2.1 que resume las características de las 5 bases de datos utilizadas en este proyecto, incluyendo el número de pacientes, el número de registros, la duración media de los mismos, el número de segmentos extraídos, el número de canales y la frecuencia de muestreo de cada base de datos.

Cuadro 2.1: Resumen comparativo de las 5 bases de datos de estudio

Base de datos	Pacientes	Registros	Dur. Media	Segmentos	Canales	Frec. Muestreo
afpdb (train) [3]	48	100	30 min	250	2	128 Hz
afpdb (test) [3]	50	100	30 min	100	2	128 Hz
cpssc2021 [4]	105	1425	20,2 min	1626	2	200 Hz
ltafdb [5]	84	84	23,3 h	1220	2	128 Hz
shdb-af [6]	122	128	23,8 h	672	2	200 Hz
afdb [7]	23	23	9,4 h	237	2	250 Hz




Figura 2.1: Distribución de segmentos de 5 minutos extraídos por clase y base de datos

Capítulo 3

Metodología

A continuación se detallan los métodos que se han seguido para la descarga, preprocesamiento de las señales, extracción de características de variabilidad de ritmo cardíaco (HRV), y las arquitecturas de las redes neuronales utilizadas para la predicción de Fibrilación Auricular a partir de segmentos de ECG en ritmo sinusal.

3.1 Descarga y lectura de bases de datos

La descarga de bases de datos se ha realizado desde el Clúster del Instituto de Investigación en Ingeniería de Aragón (I3A)¹, en concreto, en el grupo de investigación BSICoS², utilizando el gestor de descargas `wget`.

Para la lectura, se ha utilizado la librería `wfdb` de Python, que permite leer los registros ECG y extraer las anotaciones correspondientes. Puesto que el trabajo se centra en la predicción inminente, se han extraído ventanas inmediatamente anteriores a los episodios de fibrilación auricular (Pre-PAF), en concreto, de un máximo de 5 minutos anteriores al episodio, además de segmentos de control de ritmo sinusal estable.

Cada registro se ha cargado en memoria como un array de `NumPy` para su posterior procesamiento.

3.2 Preprocesamiento

El preprocesamiento es esencial por varias razones: las bases de datos utilizadas no presentan la misma frecuencia de muestreo, ni están medidas con el mismo equipo, por tanto hay que implementar un pipeline que unifique las características para que los modelos puedan generalizar correctamente. El pipeline de preprocesamiento consta de tres pasos principales:

1. **Armonización de Canales y Frecuencia de Muestreo:** Se unifican todas las señales a exactamente dos canales y una frecuencia de muestreo de 128 Hz. Si un registro tiene menos de dos canales, se realiza un relleno (`padding`) con ceros, si tiene más, se seleccionan únicamente las dos primeras derivaciones. En nuestro caso todas las bases de datos contienen 2 canales, pero se comprueba por generalidad, para tener la posibilidad de añadir posteriormente bases de datos adicionales. El remuestreo se ejecuta mediante interpolación trigonométrica.

¹<https://i3a.unizar.es/es>

²<https://bsicos.i3a.es/>

2. **Atenuación del Ruido e Interferencia:** La tarea de la eliminación del ruido se delega a las primeras capas convolucionales de los modelos, que aprenderán los filtros necesarios para su correcta eliminación, optimizados para la tarea.
3. **Normalización Z-score Local:** Para evitar sesgos debido a las variaciones inter-sujeto o inter-dispositivo en la amplitud absoluta de las señales, cada segmento se normaliza de forma independiente por canal en el dataloader aplicando:

$$x_{\text{norm}} = \frac{x - \mu}{\sigma + 10^{-8}} \quad (3.1)$$

donde μ y σ representan la media y desviación estándar de la amplitud de cada ventana.

3.3 Extracción de Ventanas y Prevención de Data Leakage

Los dos tipos de segmentos requeridos para la clasificación binaria son:

- **Clase 1 (Pre-PAF):** Esta clase representa el estado inmediatamente anterior a un episodio de fibrilación auricular. Se ha optado por extraer ventanas de longitud variable, de entre 60 (1 minuto) y 300 (5 minutos) segundos, que parten desde el inicio del episodio y retroceden en el tiempo hasta 5 minutos, o hasta encontrarse con el inicio de otro episodio. De esta manera, se garantiza que el segmento contenga solamente ritmo sinusal.
- **Clase 0 (Normal/Control):** Se extraen segmentos estables de ritmo sinusal de 5 minutos de duración, que se encuentren alejados al menos 30 minutos (1800 segundos) de cualquier episodio (tanto antes como después), para evitar zonas de transición.

Esto es importante, ya que estamos extrayendo ventanas de clase normal de pacientes tanto con PAF como sanos.

Esta estrategia es fundamental. Si la Clase 0 se compusiera solo de individuos sanos, los modelos aprenderían a identificar diferencias morfológicas asociadas a la cardiopatía estructural del paciente, en lugar de identificar los cambios transitorios que desencadenan el episodio.

Para evitar la filtración de datos (*data leakage*), los segmentos se agrupan estrictamente por sujeto. Esto garantiza que en validación y test no haya pacientes que ya hayan aparecido en el entrenamiento, ya que el modelo podría aprender a reconocer la morfología de un paciente concreto en lugar de aprender a generalizar la predicción de la fibrilación auricular.

3.4 Aumento de Datos (Data Augmentation)

Debido a que los modelos escalan mejor con grandes cantidades de datos, se ha implementado un pipeline de aumento de datos, que aplica modificaciones realistas a las señales directamente en el dataloader con una probabilidad del 50 % para cada una:

- **Deriva de la Línea de Base (*Baseline Wander*):** Se simula la deriva lenta causada por la respiración del paciente sumando una señal sinusoidal:

$$x_{\text{aug}}(t) = x(t) + A \cdot \sin(2\pi \cdot f \cdot t) \quad (3.2)$$

donde la frecuencia f se muestrea de manera uniforme en $[0,1, 0,5]$ Hz y la amplitud A en $[0,05, 0,2]$.

- **Ruido Gaussiano Aditivo:** Se simula el ruido instrumental sumando ruido blanco gaussiano con una desviación estándar variable $\sigma_{\text{noise}} \sim U(0,01, 0,05)$.
- **Escalado Aleatorio:** Se multiplica el segmento por un factor de escala $s \sim U(0,85, 1,15)$ para simular fluctuaciones en la ganancia del amplificador.
- **Slice Aleatorio de Ventana:** Dado que las redes se entrenan con ventanas de 60 segundos, y contamos con señales de hasta 5 minutos, se extraen 60 segundos aleatorios. En validación y test, se toma de forma determinista los últimos 60 segundos (el instante más cercano al inicio de la crisis en la Clase 1).

En la figura 3.1 se ilustra una demostración visual del efecto individual y combinado de estas técnicas de aumentación de datos aplicadas a un segmento real de electrocardiograma.

3.5 Extracción de Variabilidad del Ritmo Cardíaco (HRV)

Como información complementaria, se calculan nueve variables de variabilidad de ritmo cardíaco (HRV) a partir de las anotaciones de los picos QRS procedentes de las bases de datos, utilizando las ventanas de ritmo sinusal de 5 minutos. (Reescalados a 128 Hz)

- **Métricas Temporales:**

- *Media de intervalos RR* (`mean_rr`): Promedio aritmético de los intervalos, expresado en segundos.
- *Desviación estándar de intervalos RR* (`std_rr`): Medida de la variabilidad global del registro.
- *RMSSD* (`rmssd`): Raíz cuadrada de la media de las diferencias al cuadrado de intervalos sucesivos:

$$\text{RMSSD} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2} \quad (3.3)$$

- *pNN50* (`pnn50`): Porcentaje de intervalos sucesivos que difieren en más de 50 ms:

$$NN50 = \text{Número de intervalos } i \text{ tales que } |RR_{i+1} - RR_i| > 0,05 \text{ s} \quad (3.4)$$

$$pNN50 = \frac{NN50}{N-1} \times 100 \quad (3.5)$$

donde N representa el número de intervalos RR totales analizados en el segmento.




Figura 3.1: Efecto del aumento de datos sobre un segmento de ECG de 4 segundos. Se muestra (a) la señal original normalizada, (b) la adición de deriva lenta (baseline wander), (c) la adición de ruido de alta frecuencia, y (d) el resultado combinado de todas las transformaciones.

- *Frecuencia cardíaca instantánea* (mean_hr y std_hr): Obtenida para cada intervalo mediante $\text{HR}_i = 60/RR_i$ y calculando su media y desviación estándar.
- **Métricas Frecuenciales:** Dado que la serie de intervalos RR es una señal discreta de frecuencia de muestreo no uniforme debido a que depende de cada latido, se requiere un preprocesamiento para estimar la Densidad Espectral de Potencia (PSD):
 - *Interpolación y Remuestreo:* A partir de la serie temporal acumulada de los intervalos RR , se realiza una interpolación lineal y un remuestreo uniforme a una frecuencia fija de 4 Hz para que supere el límite de Nyquist requerido para la banda superior de (0,40 Hz). A la señal remuestreada se le elimina su valor medio para eliminar la componente de continua (0 Hz) y evitar distorsiones en las frecuencias bajas.
 - *Estimación de la PSD (Método de Welch):* Se aplica el método de Welch sobre la serie remuestreada a 4 Hz utilizando segmentos solapados de 256 muestras. De esta manera se establece un compromiso entre resolución en frecuencia y reducción de la varianza del estimador espectral.
 - *Energía en baja frecuencia* (lf): Potencia integrada en el rango $[0,04, 0,15)$ Hz.
 - *Energía en alta frecuencia* (hf): Potencia integrada en el rango $[0,15, 0,40]$ Hz.
 - *Relación de balance autonómico* (lf_hf_ratio):

$$\frac{\text{LF}}{\text{HF} + 10^{-8}} \quad (3.6)$$

El límite inferior de 60 segundos para la longitud de la ventana se ha establecido para garantizar la estabilidad de las métricas de HRV frecuenciales, en concreto, de la banda de baja frecuencia (LF), que requiere un mínimo de $1/0,04 = 25$ ciclos para una estimación confiable. Una ventana de 60 segundos asegura al menos 2,4 ciclos completos de dicha oscilación.

3.6 Arquitecturas de Aprendizaje Profundo

Se proponen cuatro arquitecturas para procesar la señal de entrada $\mathbf{X} \in \mathbb{R}^{2 \times L}$ (donde $L = 7680$ muestras para una ventana de 60 segundos a 128 Hz):

3.6.1 ResNet 1D (Baseline)

Basada en bloques convolucionales 1D residuales[8]. Cada bloque residual consta de capas convolucionales seguidas de (*Batch Normalization*), activación ReLU y una *skip connection*[9] que suma la entrada original a la salida del bloque, lo que facilita el paso de gradiente en arquitecturas profundas (véase el diagrama de la figura A.1 del anexo A).

3.6.2 SEResNet 1D (Atención de Canales)

Añade bloques *Squeeze-and-Excitation* (SE) tras cada bloque residual. El bloque SE comprime la información espacial del canal mediante un *Global Average Pooling* y, a través de una pequeña red *fully connected* con cuello de botella, calcula un peso de excitación para cada canal. Esto permite a la red ponderar la importancia relativa de cada una de las dos derivaciones del ECG de forma dinámica. [10] (Vease el anexo A).

3.6.3 CNN-Transformer Híbrido

Combina las fortalezas de las redes convolucionales y los mecanismos de atención. Las capas convolucionales iniciales extraen rasgos morfológicos locales y reducen la dimensión temporal de la secuencia. Posteriormente, el Transformer procesa la secuencia resultante. Utilizando mecanismos de *Multi-Head Self-Attention*, el Transformer captura dependencias temporales a lo largo de todo el segmento de ECG (Vease el anexo A).[11]

3.6.4 Mamba 1D (Modelo de Espacio de Estados)

Como alternativa al Transformer, se implementa una arquitectura basada en *State space models* (SSM) de selección variable (Mamba). Mamba parametriza un sistema lineal invariante en el tiempo que procesa la señal a través de una recurrencia lineal selectiva y dependiente de los datos. Esto permite capturar dependencias de largo alcance con una complejidad computacional que escala linealmente $O(L)$ en lugar de cuadrática $O(L^2)$ como ocurre con en el Transformer (Vease el anexo A).

3.6.5 Integración de Características HRV

Adicionalmente, se concatenan a la salida de los modelos a la cabeza clasificatoria (MLP) las 9 variables de HRV. Finalmente, esta representación combinada se introduce en una capa lineal clasificadora con activación Softmax para emitir la probabilidad de Pre-PAF.

3.7 Estrategia de Evaluación y Validación Cruzada

El diseño experimental se define mediante:

- **Validación Cruzada (5-Fold GroupKFold):** El dataset total se divide en 5 *folds* de forma que todos los segmentos de un mismo paciente queden en el mismo *fold*. En cada iteración, se entrenan los modelos en 4 *folds* y se validan en el restante.
- **Evaluación Externa:** Para comparar los modelos en igualdad de condiciones con la literatura científica, los modelos se evalúan adicionalmente en el conjunto de prueba independiente de la base de datos afpdb (PAF Prediction Challenge).
- **Métricas de Calidad:** Se evalúa el rendimiento utilizando la sensibilidad (Recall), especificidad, precisión, puntuación F1 macro (F1 Macro), F1 de la clase Pre-PAF (F1 Clase 1) y el área bajo la curva ROC (AUC-ROC).

Capítulo 4

Resultados y Discusión

En este capítulo se presentan los resultados obtenidos por las cuatro arquitecturas implementadas (ResNet 1D, SEResNet 1D, el modelo híbrido CNN-Transformer y Mamba 1D). El entrenamiento se ha realizado mediante una validación cruzada por grupos (5-Fold Group Cross-Validation), asegurando que los registros de un mismo sujeto nunca se compartan entre los conjuntos de entrenamiento y validación.

Para la comparación con otros trabajos publicados, también se evalúa en un conjunto de test independiente [3].

4.1 Resultados detallados por arquitectura

A continuación se presentan los resultados obtenidos para cada una de las arquitecturas.

4.1.1 Arquitectura ResNet 1D

Para optimizar el rendimiento de la ResNet 1D, se parametrizó la arquitectura base para y evaluar el impacto de las siguientes variables de diseño:

- **Profundidad de la red:** Variación del número de bloques residuales por capa. El baseline original utiliza 8 bloques (configuración [2, 2, 2, 2]), mientras que la variante profunda utiliza 12 bloques ([3, 3, 3, 3]).
- **Ancho de la red:** Modificación del número de canales convolucionales en las capas sucesivas (baseline original: [32, 64, 128, 256] frente a la versión ancha: [64, 128, 256, 512]).
- **Tamaño del kernel:** Comparación del tamaño del kernel en las convoluciones 1D (baseline: 15 muestras, frente a kernels grandes de 23 y pequeños de 7).
- **Profundidad y Estrechez:** Una combinación de mayor profundidad (15 bloques distribuidos como [3, 4, 6, 3]) con un menor número de canales ([24, 48, 96, 192]) para restringir el número total de parámetros de la red y mitigar el sobreajuste.
- **Aumento de Datos (Data Augmentation):** Evaluación de cada una de las arquitecturas anteriores bajo aumentación de datos (ruido gaussiano, baseline wander y escalado de señal).

Los resultados obtenidos por cada variante mediante validación cruzada de 5 *folds* por grupos se resumen en la Tabla 4.1.

De los resultados de la Tabla 4.1, vemos como en este caso La ResNet Profunda (deep) sin aumentación de datos es la variante que obtiene el mejor resultado en validación cruzada (F1 Macro de

Cuadro 4.1: Resultados de las variaciones de la arquitectura ResNet 1D con y sin aumento de datos

Configuración ResNet 1D	Augment.	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
ResNet Base	No	$0,7591 \pm 0,04$	0.80	0.80	46 %
	Sí	$0,7473 \pm 0,04$	0.78	0.79	64 %
ResNet Profunda (deep)	No	$0,7863 \pm 0,04$	0.82	0.82	36 %
	Sí	$0,7501 \pm 0,04$	0.80	0.80	50 %
ResNet Ancha (wide)	No	$0,7439 \pm 0,04$	0.77	0.77	50 %
	Sí	$0,7447 \pm 0,06$	0.80	0.81	57 %
ResNet Kernel Grande (k=23)	No	$0,7464 \pm 0,04$	0.80	0.80	54 %
	Sí	$0,7417 \pm 0,05$	0.77	0.77	46 %
ResNet Kernel Pequeño (k=7)	No	$0,7378 \pm 0,06$	0.83	0.83	57 %
	Sí	$0,7461 \pm 0,04$	0.79	0.79	46 %
ResNet Profunda y Estrecha	No	$0,7496 \pm 0,06$	0.81	0.81	54 %
	Sí	$0,7306 \pm 0,06$	0.79	0.80	54 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado de afpdb [3].

$0,7863 \pm 0,04$), y se traslada de forma muy sólida al conjunto de test independiente, donde alcanza un F1 Macro de 0.82 y un Accuracy de 0.8.

También se observa que la profundidad de la red es el factor mas determinante, le permite tener mas campo receptivo y resulta en una mejor extracción de características morfológicas de la señal ECG. Aumentar el ancho de la red o el tamaño del kernel no aporta mejoras observables. El aumento de datos parece no aportar mejoras en este caso. Dependiendo del modelo, y de la aumentación, podría estar introduciendo características propias de una clase en la otra.

Las puntuaciones del reto externo son menos predecibles, con un rango de 36 % – 64 %. El modelo no generaliza a este dataset, debido a la poca representación de ese dataset en nuestro conjunto de entrenamiento completo, el modelo prioriza la generalidad a todos los datasets, y no se especializa en el reto.

4.1.2 Arquitectura SEResNet 1D con atención de canales

Para evaluar si los mecanismos de atención por canal (Squeeze-and-Excitation, [10]) ofrecen ventajas, se parametrizó la arquitectura base y se evaluó el impacto de las variables de diseño (profundidad, ancho, tamaño de kernel y la combinación profunda-estrecha) tanto con como sin aumento de datos.

Los resultados obtenidos se detallan en la Tabla 4.2.

De los resultados de la Tabla 4.2 concluimos que la arquitectura SEResNet Profunda y Estrecha con aumentación de datos es la que obtiene el mejor resultado en validación cruzada (F1 Macro de $0,7680 \pm 0,05$). También obtiene un resultado consistente en el conjunto de test independiente, con un F1 Macro de 0,79 y un Accuracy de 0,79.

El bloque SE permite a la red ponderar la importancia de cada canal, dependiendo de cuanta información relevante contenga cada uno. En holters donde la señal se puede degradar por desprendimientos de electrodos o por otras razones es de especial utilidad. Se muestra en como responde ante la aumentación de datos. Al perturbar la señal, obligamos a la red a aprender a ponderar los canales ante señales no ideales, haciendo la red mas robusta.

Cuadro 4.2: Resultados de las variaciones de la arquitectura SEResNet 1D con y sin aumento de datos

Configuración SEResNet 1D	Augment.	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
SEResNet Base	No	0,7619 $\pm$ 0,06	0.80	0.80	50 %
	Sí	0,7426 $\pm$ 0,05	0.79	0.79	50 %
SEResNet Profunda	No	0,7394 $\pm$ 0,05	0.80	0.80	54 %
	Sí	0,7379 $\pm$ 0,04	0.78	0.78	57 %
SEResNet Ancha	No	0,7440 $\pm$ 0,05	0.83	0.83	54 %
	Sí	0,7625 $\pm$ 0,05	0.81	0.81	57 %
SEResNet Kernel Grande	No	0,7527 $\pm$ 0,04	0.78	0.78	50 %
	Sí	0,7416 $\pm$ 0,05	0.80	0.80	54 %
SEResNet Kernel Pequeño	No	0,7540 $\pm$ 0,05	0.83	0.83	46 %
	Sí	0,7583 $\pm$ 0,02	0.76	0.76	46 %
SEResNet Profunda y Estrecha	No	0,7439 $\pm$ 0,06	0.80	0.80	43 %
	Sí	0,7680 $\pm$ 0,05	0.79	0.79	54 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado de afpdb [3].

Aunque obtengamos en otras variantes mejores resultados en test independiente, (las variantes SEResNet Ancha y SEResNet Kernel Pequeño (ambas sin aumentación) obtienen un F1 de 0.83 y Accuracy del 0.83) la SEResNet Profunda y Estrecha con aumentación de datos es la que obtiene el mejor resultado en validación cruzada, y es la que se debe escoger de manera estricta.

El score del reto externo sigue siendo inestable, la razón es la misma que en el caso de la ResNet 1D.

4.1.3 Arquitectura CNN-Transformer Híbrida y variaciones estructurales

Para intentar superar las limitaciones del modelo base CNN-Transformer, se comparan las siguientes variaciones estructurales entrenadas con y sin aumento de datos:

- **Transformer Base:** La arquitectura baseline con $d_{model} = 128$, 4 cabezas de atención ($n_{head} = 4$) y 3 capas de codificación.
- **Transformer Profundo:** Incremento del número de capas del codificador de 3 a 6 para captar relaciones temporales más abstractas.
- **Transformer Ancho:** Aumento de la capacidad del modelo a $d_{model} = 256$, 8 cabezas ($n_{head} = 8$) y dimensión de feedforward a 512.
- **Transformer Dropout Aumentado:** Elevación del factor de *dropout* de 0.2 a 0.4 para mitigar el sobreajuste.
- **Transformer Estrecho (Narrow):** Reducción de parámetros ($d_{model} = 64$, $n_{head} = 2$, feedforward de 128) para forzar un cuello de botella de información que prevenga la memorización.

Los resultados se detallan en la Tabla 4.3.

De los resultados de la Tabla 4.3 concluimos que la arquitectura Transformer Ancho con aumentación de datos es la que obtiene el mejor resultado en validación cruzada (F1 Macro de 0,7727 $\pm$ 0,05) y con el test independiente corroborando su generalización con un F1 Macro de 0.80 y una exactitud del 0.80. Le

Cuadro 4.3: Resultados de las variaciones de la arquitectura CNN-Transformer 1D con y sin aumento de datos

Configuración Transformer 1D	Augment.	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
Transformer Base	No	$0,7536 \pm 0,05$	0.81	0.81	57 %
	Sí	$0,7723 \pm 0,04$	0.79	0.79	46 %
Transformer Profundo	No	$0,7474 \pm 0,03$	0.81	0.81	57 %
	Sí	$0,7634 \pm 0,04$	0.80	0.80	57 %
Transformer Ancho	No	$0,7666 \pm 0,03$	0.79	0.79	46 %
	Sí	$0,7727 \pm 0,05$	0.80	0.80	46 %
Transformer Dropout Aumentado	No	$0,7562 \pm 0,03$	0.77	0.78	46 %
	Sí	$0,7567 \pm 0,03$	0.75	0.75	46 %
Transformer Estrecho	No	$0,7469 \pm 0,04$	0.78	0.78	50 %
	Sí	$0,7645 \pm 0,02$	0.77	0.77	50 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado de afpdb [3].

sigue de cerca la variante Transformer Base con aumentación, que obtiene un F1 Macro de $0,7723 \pm 0,04$ en validación cruzada y un F1 Macro de 0.79 en test independiente.

Disponer de mas cabezas de atención y mayor dimensión latente le permite al modelo obtener mejores resultados. En este caso y a diferencia de las arquitecturas convolucionales, el aumento de datos si aporta mejoras en el rendimiento del modelo, la regularización de la señal beneficia a la arquitectura de atención, que es más propensa al sobreajuste.

El score del reto externo sigue siendo inestable, la razón es la misma que en el caso de la ResNet 1D y SEResNet 1D.

4.1.4 Arquitectura Mamba 1D y capacidad de representación

El modelo Mamba 1D, basado en modelos de espacio de estados selectivos (SSM), se evalúa como alternativa eficiente frente a las arquitecturas convolucionales y de atención temporal. Su rendimiento se detalla en la comparativa inter-modelo general.

4.2 Evaluación comparativa inter-modelo

El rendimiento de los mejores modelos seleccionados para cada arquitectura se evalúa a través de las métricas: exactitud global (Accuracy), precisión, sensibilidad (Recall) y la puntuación F1 (F1-score) tanto por clase como promedio (Macro F1). Los resultados se detallan en la Tabla 4.4.

Analizando la comparación de la Tabla 4.4, la mejor arquitectura es la ResNet 1D Profunda sin aumentación de datos, que obtiene el mayor F1 Macro en validación cruzada ($0,7863 \pm 0,04$) y mantiene un rendimiento sólido en el conjunto de test independiente con un F1 Macro de 0,82 y una exactitud del 0,82. También se observa como su F1 Clase 0 (Ritmo Sinusal) es de 0,84 y su F1 Clase 1 (Pre-PAF) es de 0,79, lo que indica un buen equilibrio entre ambas clases.

Las convolucionales parecen obtener mejores resultados que las arquitecturas de atención, aunque la diferencia no es muy grande. El modelo Mamba 1D obtiene un rendimiento sólido, con un F1 Macro de $0,7138 \pm 0,09$ en validación cruzada y un F1 Macro de 0,75 en el conjunto de test independiente,

Cuadro 4.4: Resultados del rendimiento de las mejores variantes de cada arquitectura (seleccionadas según su F1 en validación) en validación y test

Modelo	Split	F1 Clase 0	F1 Clase 1	F1 Macro	Accuracy
ResNet 1D (Profunda, Sin Aug)	Validación (CV)	—	—	$0,7863 \pm 0,04$	$0,7964 \pm 0,04$
	Test	0.84	0.79	0.82	0.82
Transformer (Ancho, Aug)	Validación (CV)	—	—	$0,7727 \pm 0,05$	$0,7887 \pm 0,04$
	Test	0.82	0.78	0.80	0.80
SEResNet 1D (Profunda-Estrecha, Aug)	Validación (CV)	—	—	$0,7680 \pm 0,05$	$0,7809 \pm 0,04$
	Test	0.82	0.76	0.79	0.79
Mamba 1D	Validación (CV)	—	—	$0,7138 \pm 0,09$	$0,7350 \pm 0,09$
	Test	0.75	0.74	0.75	0.75

Nota: La Clase 0 corresponde a Ritmo Sinusal y la Clase 1 a la ventana crítica anterior a la Fibrilación Auricular (Pre-PAF).

lo que indica una buena capacidad de generalización, aunque queda por detrás de las arquitecturas convolucionales y de atención.

4.3 Análisis de resultados y discusión

4.3.1 Discrepancia entre el rendimiento en test general y el benchmark de PhysioNet

Un hallazgo clave de este trabajo es la discrepancia observada entre el rendimiento en el conjunto de prueba general y las puntuaciones en el reto oficial de PhysioNet (afpdb):

- Originalmente se fue más estricto a la hora de extraer ventanas, asumiendo que si no se encontraban 5 minutos completos, no se consideraba. Esto dejó a la base de datos afpdb como una fuente altamente representativa, y por ello los modelos obtenían puntuaciones altas en el reto (hasta 79 % en el CNN-Transformer y 75 % en la ResNet 1D), pero a costa de un F1-score muy bajo en condiciones generales (56 % y 61 % respectivamente).
- Tras realizar el aumento de datos mediante ventanas variables, el volumen de la base de datos del reto (afpdb) pasa a representar solo el 2.65 % del total de Clase 1 en el entrenamiento, que ahora es dominado por registros de Holter ambulatorio de 24 horas (1tafdb) y dispositivos corporales inteligentes (shdb-af).
- Como consecuencia directa, la generalización ante nuevos sujetos mejora notablemente (alcanzando el 82 % de F1 en la ResNet optimizada), pero las puntuaciones del reto específico se vuelven inestables.

Al optimizar los modelos con un dataset más grande, las redes aprenden a priorizar rasgos generales de ECG ambulatorio y wearables. Sin embargo, esto diluye la especialización del modelo a la base de datos afpdb original.

4.3.2 Estudio de la contribución de la variabilidad del ritmo cardíaco (HRV)

Para evaluar el impacto de las variables de variabilidad del ritmo cardíaco (HRV) en el proceso de decisión del clasificador, se comparó un modelo (el híbrido **Transformer Estrecho con Aumento de Datos**) frente a dos configuraciones:

- **Configuración de solo señal:** Se reentrenó la misma arquitectura del Transformer Estrecho y Aumentado eliminando por completo la rama de entrada de HRV, forzando a la red a basar sus predicciones únicamente en los 60 segundos de morfología de señal de ECG.
- **Configuración de solo características HRV:** Se entrenaron dos clasificadores clásicos (un *Random Forest*, y un *Gradient Boosting*) que recibieron exclusivamente las 9 características de HRV locales calculadas a partir de las ventanas de ritmo sinusal, aisladas de cualquier información morfológica del ECG.

Los resultados obtenidos mediante esta estrategia se presentan en la Tabla 4.5.

Cuadro 4.5: Resultados del estudio de contribución de HRV frente al modelo híbrido completo

Modelo	Modalidad de Entrada	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
Transformer Narrow (Aug)	Híbrido (ECG + HRV)	0,7645 ± 0,02	0.77	0.77	50 %
Transformer Narrow (Aug)	Solo ECG	0,7518 ± 0,02	0.76	0.76	50 %
Random Forest	Solo HRV	0,7137 ± 0,05	0.82	0.82	71 %
Gradient Boosting	Solo HRV	0,6978 ± 0,04	0.82	0.82	61 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado de afpdb [3].

De los resultados de la Tabla 4.5 se extraen varias conclusiones. El objetivo del experimento era evaluar si el análisis de las redes neuronales a partir de 60 s de ECG es competitivo frente a modelos clásicos basados únicamente en variables de HRV, y si la combinación de ambas fuentes de información mejora el clasificador.

En primer lugar, el modelo híbrido (*ECG + HRV*) supera al modelo basado en *Solo ECG* en validación (0,7645 frente a 0,7518) y en test local (0,77 frente a 0,76 de F1 Macro). Lo que nos dice que la red se beneficia de la información que le aportan las variables HRV.

El clasificador basado únicamente en características HRV (*Random Forest*) obtiene un F1 Macro de 0,7137 ± 0,05 en validación cruzada, y un F1 Macro de 0,82 en el conjunto de test independiente, lo que indica que las variables HRV contienen información de gran utilidad para la predicción de fibrilación auricular. Aunque no obtenga en validación el mejor resultado, no se queda atrás.

En concreto obtiene un 71 % de acierto en el reto PhysioNet. Dado que el volumen de datos clínicos del estudio es acotado, las redes neuronales, por muy complejas que sean, no disponen de datos suficientes para aprovechar su capacidad de analizar la morfología de la señal, lo que justifica la competitividad del modelo clásico.

En segundo lugar, al evaluar la generalización clínica en el test externo del reto, aunque el modelo clásico se posicionaba como el mejor, no obtiene resultados competitivos, debido tanto a la inestabilidad que hemos comentado a lo largo del trabajo del que presenta el score del reto, como quizá la falta de generalización de un modelo que no tiene en cuenta la morfología de la señal que se está tratando.

4.4 Comparación con trabajos relacionados

La mayoría de los algoritmos publicados en la literatura científica que evalúan su rendimiento en el PAF Prediction Challenge (afpdb[3]) entrenan sus modelos únicamente utilizando los datos de la base de datos afpdb, o de bases de datos específicas. Aunque algunos logran clasificaciones sobresalientes en este benchmark específico (79 % de precisión), carecen de la generalidad que ofrecen estos modelos.

Este trabajo demuestra que el entrenamiento exclusivo sobre una única base de datos induce un sesgo de adquisición artificial. Al contrastar nuestros modelos con una validación cruzada inter-sujeto sobre cinco bases de datos, demostramos la viabilidad de un predictor de PAF generalizable capaz de mantener una alta sensibilidad y especificidad incluso en señales capturadas por wearables en condiciones cotidianas.

Capítulo 5

Conclusiones y Líneas Futuras

A continuación se presentan las conclusiones finales del proyecto, cumplimiento de objetivos, valoraciones y líneas futuras de investigación derivadas de este trabajo.

5.1 Resumen y aportaciones del proyecto

Este trabajo ha abordado el problema de la predicción inminente de la Fibrilación Auricular Paroxística (PAF) a partir de señales de electrocardiograma en ritmo sinusal. Las principales contribuciones de este proyecto incluyen:

- **Pipeline de Preprocesamiento Armonizado y Dinámico:** Se ha diseñado un pipeline capaz de unificar cinco bases de datos de distinta procedencia (afpdb, cpsc2021, 1tafdb, shdb-af y afdB) gestionando discrepancias entre ellas como frecuencias de muestreo distintas, que obliga a un resampleo uniforme a 128 Hz.
- **Evaluación Comparativa de Arquitecturas:** Se han comparado bajo validación cruzada por grupos (inter-sujeto) redes neuronales residuales (ResNet 1D), mecanismos de atención por canal (SE-ResNet 1D), autoatención temporal híbrida (CNN-Transformer) y el modelo de espacio de estados selectivo (Mamba 1D).
- **Demostración de la Sinergia Híbrida (ECG + HRV):** Se ha corroborado empíricamente que la inclusión conjunta de información morfológica a corto plazo (ECG con una ventana de 10 s) y a mediano plazo (HRV en ventana de 5 min) proporciona una mejora en la clasificación.

5.2 Cumplimiento de objetivos

Se ha alcanzado con éxito el propósito principal del trabajo a través de los siguientes hitos:

- **Detección del estado crítico Pre-PAF:** Se ha logrado identificar las variaciones morfológicas que llevan a un episodio de fibrilación auricular en la ventana crítica de 5 minutos inmediatamente anterior al episodio, logrando un F1-score del 0.82 (con un F1 de 0.79 en la clase crítica Pre-PAF y una exactitud del 82 %) mediante la configuración ResNet 1D, o si atendemos a modelos clásicos con un F1-score de 0,82 con *Random Forest*.
- **Mitigación del Data Leakage:** La separación estricta de conjuntos de datos agrupando por paciente garantiza que las métricas de rendimiento reportadas no estén sesgadas por memorización de morfologías específicas de un sujeto.

- **Estudio de la contribución HRV:** Se evaluó el peso relativo de la morfología del ECG y las características HRV.

5.3 Valoración crítica y limitaciones

El estudio presenta limitaciones que deben ser consideradas:

- **Volumen acotado de datos clínicos:** El aprendizaje profundo requiere volúmenes masivos de datos para obtener los mejores resultados. En este proyecto, la cantidad limitada de señales explica que arquitecturas muy sofisticadas (como el Transformer o SEResNet) muestren un sobreajuste local clasificadores clásicos como el *Random Forest* alimentado con datos HRV precalculados no se queden tan atrás. Además, el número de señales no se corresponde con el número de pacientes, ya que un paciente puede tener mas de una señal, en concreto, contamos con 4.005 señales de 380 pacientes, que no es diversidad suficientes para captar anomalías morfológicas heterogéneas.
- **Compromiso temporal en la ventana mínima de HRV:** Garantizar un mínimo de 1 minuto (60 s) ha sido indispensable para estabilizar el cálculo espectral de las bandas de baja frecuencia (LF, 0,04–0,15 Hz). Sin embargo, esta restricción impone un compromiso, ya que estamos descartando ventanas válidas que no cumplían con este criterio

5.4 Líneas futuras

A continuación, se proponen las siguientes líneas de desarrollo futuro:

- **Exploración de Modelos Fundacionales Preentrenados (Signal Transformers):** Investigar la transferencia de aprendizaje utilizando modelos auto-supervisados entrenados en millones de horas de ECG clínicos, lo que resolvería la limitación del tamaño de datos local.
- **Validación en Tiempo Real y Wearables:** Evaluar los clasificadores embebidos en dispositivos en tiempo real, validando su sensibilidad ante el ruido de movimiento cotidiano.

Referencias

- [1] *Electrocardiography*, en *Wikipedia*, Page Version ID: 1358826471, 11 de jun. de 2026. dirección: <https://en.wikipedia.org/w/index.php?title=Electrocardiography&oldid=1358826471>
- [2] *Atrial fibrillation*, en *Wikipedia*, Page Version ID: 1350567686, 22 de abr. de 2026. dirección: https://en.wikipedia.org/w/index.php?title=Atrial_fibrillation&oldid=1350567686
- [3] G. B. Moody, A. L. Goldberger, S. McClennen y S. P. Swiryn, *PAF Prediction Challenge Database*, 2001. DOI: 10.13026/C2H59W dirección: <https://physionet.org/content/afpdb/>
- [4] X. Wang, C. Ma, X. Zhang, H. Gao, G. D. Clifford y C. Liu, "Paroxysmal Atrial Fibrillation Events Detection from Dynamic ECG Recordings: The 4th China Physiological Signal Challenge 2021", *PhysioNet*, jun. de 2021, Version 1.0.0. DOI: 10.13026/ksya-qw89 dirección: <https://doi.org/10.13026/ksya-qw89>
- [5] S. Petrutiu, A. V. Sahakian y S. Swiryn, *The Long-Term AF Database*, 2003. DOI: 10.13026/C2QG6Q dirección: <https://physionet.org/content/ltafdb/>
- [6] K. Tsutsui, S. Biton Brimer y J. Behar, "SHDB-AF: a Japanese Holter ECG database of atrial fibrillation", *PhysioNet*, abr. de 2025, Version 1.0.1. DOI: 10.13026/n6yq-fq90 dirección: <https://doi.org/10.13026/n6yq-fq90>
- [7] G. B. Moody y R. G. Mark, *MIT-BIH Atrial Fibrillation Database*, 1992. DOI: 10.13026/C2MW2D dirección: <https://physionet.org/content/afdb/>
- [8] P. Rajpurkar, A. Y. Hannun, M. Haghpahani, C. Bourn y A. Y. Ng, *Cardiologist-Level Arrhythmia Detection with Convolutional Neural Networks*, 2017. arXiv: 1707.01836 [cs.CV]. dirección: <https://arxiv.org/abs/1707.01836>
- [9] K. He, X. Zhang, S. Ren y J. Sun, *Deep Residual Learning for Image Recognition*, 2015. arXiv: 1512.03385 [cs.CV]. dirección: <https://arxiv.org/abs/1512.03385>
- [10] J. Hu, L. Shen y G. Sun, "Squeeze-and-Excitation Networks", en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, jun. de 2018, págs. 7132-7141. DOI: 10.1109/CVPR.2018.00745
- [11] A. Vaswani et al., "Attention Is All You Need", 2023. arXiv: 1706.03762 [cs.CL]. dirección: <https://arxiv.org/abs/1706.03762>
- [12] A. Gu y T. Dao, "Mamba: Linear-Time Sequence Modeling with Selective State Spaces", 2024. arXiv: 2312.00752 [cs.LG]. dirección: <https://arxiv.org/abs/2312.00752>

Anexos

Apéndice A

Detalle de las Arquitecturas de Aprendizaje Profundo

En este anexo se describen con mayor profundidad las especificaciones de diseño de las cuatro arquitecturas de redes neuronales evaluadas en este proyecto.

A.1 ResNet 1D

La red convolucional residual (ResNet 1D)[9] implementa la arquitectura base para la extracción de rasgos morfológicos de los canales de ECG. La característica distintiva de ResNet es la adición de conexiones de atajo (*skip connections*)[8], que suman la entrada de un bloque residual a su salida:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + W_s \mathbf{x} \quad (\text{A.1})$$

donde $\mathbf{x}$ e $\mathbf{y}$ son los vectores de entrada y salida, respectivamente, $\mathcal{F}$ representa la función de mapeo residual a aprender, y W_s es una proyección lineal utilizada únicamente cuando es necesario ajustar las dimensiones de los canales.

El flujo detallado de la señal a través de la arquitectura y la concatenación de las características de variabilidad del ritmo cardíaco (HRV) se representan en la figura A.1.

A.2 SEResNet 1D

La arquitectura SEResNet 1D se basa en la incorporación de módulos *Squeeze-and-Excitation* (SE) en los bloques residuales convencionales. Esta adición recalibra adaptativamente las respuestas de los canales, modelando las dependencias entre ellos para mejorar el rendimiento de la red.[10]

El módulo SE, detallado en la figura A.2, consta de dos pasos principales:

1. **Squeeze (Compresión):** Se realiza un promedio global a lo largo de la dimensión temporal L para resumir la información del canal c , produciendo un vector de características globales:

$$z_c = \frac{1}{L} \sum_{i=1}^L u_c(i) \quad (\text{A.2})$$

2. **Excitation (Excitación):** Se calcula una escala de pesos no lineal basada en las interdependencias




Figura A.1: Arquitectura base ResNet 1D. La red procesa la entrada reduciendo progresivamente la dimensión temporal mediante bloques residuales, integrando finalmente las características HRV antes del clasificador *fully connected*.

de los canales mediante un cuello de botella con dos capas densas:

$$\mathbf{s} = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot \mathbf{z})) \quad (\text{A.3})$$

donde σ es la función sigmoide, $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ y $W_2 \in \mathbb{R}^{C \times \frac{C}{r}}$, siendo r el factor de reducción.

El esquema correspondiente al módulo SE se muestra en la figura A.2.




Figura A.2: Módulo Squeeze-and-Excitation. Tras cada bloque residual se incorpora este módulo que recalibra adaptativamente los pesos de los canales. Obtenida del paper original [10]

El flujo secuencial se ilustra en la figura A.3.

A.3 CNN-Transformer Híbrido

La arquitectura híbrida utiliza codificadores Transformer para capturar dependencias a largo plazo gracias al mecanismo de autoatención (*Multi-Head Self-Attention*, MHSA). Dada una matriz de proyección




Figura A.3: Arquitectura SEResNet 1D. Tras cada bloque residual se incorpora un módulo Squeeze-and-Excitation que recalibra adaptativamente los pesos de los canales de extracción de características.

de consultas ($\mathbf{Q}$), claves ($\mathbf{K}$) y valores ($\mathbf{V}$), la atención de una sola cabeza se define como:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (\text{A.4})$$

donde d_k es la dimensión de las claves. La autoatención concatena múltiples cabezas de atención proyectadas linealmente para capturar diferentes relaciones de contexto simultáneamente. [11]

El diagrama del codificador híbrido se muestra en la figura A.4.

A.4 Mamba 1D

Mamba introduce los modelos de espacio de estados estructurados selectivos (*Selective Structured State Space Models, S4*), los cuales permiten procesar secuencias con una complejidad temporal lineal respecto a la longitud de la entrada, manteniendo a la vez un mecanismo de atención selectivo basado en el contexto.

En el dominio continuo, estos modelos mapean una señal unidimensional de entrada $x(t) \in \mathbb{R}$ a una representación latente $h(t) \in \mathbb{R}^N$ mediante una ecuación diferencial lineal de primer orden, para luego proyectarla hacia la salida $y(t) \in \mathbb{R}$:

$$h'(t) = \mathbf{A}h(t) + \mathbf{B}x(t), \quad y(t) = \mathbf{C}h(t) + \mathbf{D}x(t) \quad (\text{A.5})$$

Para su implementación en datos discretos, estas ecuaciones se formulan mediante un paso de discretización Δ . La principal innovación de Mamba radica en su mecanismo de selección, haciendo que




Figura A.4: Arquitectura híbrida CNN-Transformer. Se utiliza un *frontend* convolucional para la extracción local y reducción de dimensionalidad, seguido de codificadores posicionales y un *Transformer Encoder* para la atención global.

las matrices de transición $\mathbf{B}$ y $\mathbf{C}$, así como el propio parámetro de escala Δ , sean funciones directas de la entrada x_t . Esto rompe la invarianza en el tiempo de los SSM tradicionales y permite al sistema decidir activamente qué información propagar o descartar a lo largo de la secuencia de manera dinámica. [12]

La estructura interna del bloque Mamba y el flujo de los datos a través del módulo de selección se ilustran en la figura A.5.

El flujo secuencial se ilustra en la figura A.6.




Figura A.5: Estructura interna del bloque Mamba. Se detalla el mecanismo del modelo de espacio de estados selectivo (SSM), donde los parámetros de discretización y transición se calculan de manera dinámica en función de la secuencia de entrada.




Figura A.6: Arquitectura híbrida CNN-Mamba. La secuencia latente generada por el *frontend* convolucional es procesada de forma puramente secuencial mediante bloques SSM selectivos, prescindiendo de codificadores posicionales.