



Universidad
Zaragoza

Trabajo Fin de Grado

Predicción de fibrilación auricular paroxística a partir
del electrocardiograma en ritmo sinusal mediante el
análisis con redes neuronales profundas

*Prediction of Paroxysmal Atrial Fibrillation from the
Sinus Rhythm Electrocardiogram Using Deep Neural
Networks*

Autor

Diego Bouchet Agudo

Directores

Juan Pablo artínez Cortés

Antonio Miguel Artiaga

Titulación

Grado en Ingeniería de Tecnologías y Servicios de Telecomunicación

Escuela de Ingeniería y Arquitectura (EINA)

2026

Resumen

Título del trabajo

Predicción de fibrilación auricular paroxística a partir del electrocardiograma en ritmo sinusal mediante el análisis con redes neuronales profundas

English Title

Prediction of Paroxysmal Atrial Fibrillation from the Sinus Rhythm Electrocardiogram Using Deep Neural Networks

RESUMEN

La Fibrilación Auricular Paroxística (PAF) es una de las arritmias cardíacas más comunes y un factor de riesgo crítico para el desarrollo de accidentes cerebrovasculares e insuficiencia cardíaca. Su diagnóstico y tratamiento tempranos son complejos debido a su naturaleza intermitente, por lo que la predicción de episodios inminentes antes de su inicio a partir de segmentos de electrocardiograma (ECG) en ritmo sinusal representa una valiosa oportunidad clínica de prevención. Este Trabajo de Fin de Grado aborda este desafío mediante la implementación de un pipeline unificado de aprendizaje profundo y procesamiento de señales electrocardiográficas.

Para asegurar la capacidad de generalización de los modelos y evitar los sesgos de adquisición de hardware comunes en la literatura, se consolidó un dataset masivo a partir de cinco bases de datos públicas de PhysioNet. Se diseñó un preprocesamiento dinámico que extrae ventanas de duración variable previas a las crisis cardíacas y calcula automáticamente nueve variables de variabilidad del ritmo cardíaco (HRV). Se implementaron y evaluaron cuatro arquitecturas de red neuronal 1D: ResNet 1D (baseline), SEResNet 1D (con atención de canales), un híbrido CNN-Transformer y Mamba 1D (modelo de espacio de estados selectivo). Para evitar la filtración de datos, los experimentos se validaron de forma cruzada agrupando estrictamente por sujeto (5-Fold GroupKFold).

Los resultados cuantitativos en un conjunto de prueba independiente demuestran la superioridad de la SEResNet 1D con un F1 Macro del 79 % y un destacado F1-score del 81 % en la clase crítica Pre-PAF, seguido por el modelo Mamba 1D con un 75 % de F1 Macro. Adicionalmente, se discute y analiza el impacto del desplazamiento de dominio (Domain Shift) al evaluar los modelos frente al benchmark blindado del reto de PhysioNet. Este estudio valida la viabilidad de un sistema inteligente generalizable inter-sujeto e inter-base de datos para la monitorización preventiva y alerta temprana de crisis arrítmicas.

Palabras clave: Fibrilación Auricular Paroxística, Predicción Inminente, Procesamiento de ECG, Aprendizaje Profundo, Variabilidad del Ritmo Cardíaco (HRV), Mamba.

ABSTRACT

Paroxysmal Atrial Fibrillation (PAF) is one of the most common cardiac arrhythmias and a critical risk factor for stroke and heart failure. Its early diagnosis and treatment are challenging due to its intermittent nature; thus, predicting imminent episodes before onset using electrocardiogram (ECG) segments in sinus rhythm represents a valuable preventive clinical opportunity. This Bachelor's Thesis addresses this challenge through the implementation of a unified pipeline of deep learning and ECG signal processing.

To ensure the generalization of the models and avoid the hardware acquisition biases common in the literature, a massive dataset was consolidated from five public PhysioNet databases. A dynamic pre-processing pipeline was designed to extract variable-length windows prior to cardiac crises and compute nine classic heart rate variability (HRV) features. Four 1D neural network architectures were implemented and evaluated: 1D ResNet (baseline), 1D SEResNet (with channel-wise attention), a hybrid CNN-Transformer, and Mamba 1D (selective state space model). To prevent data leakage, experiments were cross-validated by grouping strictly by subject (5-Fold GroupKFold).

Quantitative results on an independent test set demonstrate the superiority of the 1D SEResNet with a Macro F1-score of 79% and a remarkable F1-score of 81% in the critical Pre-PAF class, followed by the Mamba 1D model with a 75% Macro F1-score. Additionally, the impact of domain shift is discussed when evaluating the models against the blinded benchmark of the official PhysioNet Challenge. This study validates the feasibility of a generalizable, cross-subject, and cross-database intelligent system for preventive monitoring and early warning of arrhythmic events.

Keywords: Paroxysmal Atrial Fibrillation, Imminent Prediction, ECG Signal Processing, Deep Learning, Heart Rate Variability (HRV), Mamba.

Índice general

Resumen	I
1 Introducción	1
1.1 Contexto del Trabajo	2
1.2 Objetivos del Proyecto	3
2 Datos	4
2.1 Bases de datos utilizadas	4
2.1.1 PAF Prediction Challenge Database (afpdb)	4
2.1.2 China Physiological Signal Challenge 2021 (cpssc2021)	4
2.1.3 Long-Term Atrial Fibrillation Database (ltafdb)	4
2.1.4 Smart Health Devices - Atrial Fibrillation Database (shdb-af)	5
2.1.5 MIT-BIH Atrial Fibrillation Database (afdb)	5
2.2 Características comparativas de los conjuntos de datos	5
3 Metodología	6
3.1 Descarga y lectura de bases de datos	6
3.2 Preprocesamiento	6
3.3 Extracción de Ventanas y Prevención de Data Leakage	7
3.4 Aumento de Datos (Data Augmentation)	7
3.5 Extracción de Variabilidad del Ritmo Cardíaco (HRV)	8
3.6 Arquitecturas de Aprendizaje Profundo	8
3.6.1 ResNet 1D (Baseline)	8
3.6.2 SEResNet 1D (Atención de Canales)	9
3.6.3 CNN-Transformer Híbrido	9
3.6.4 Mamba 1D (Modelo de Espacio de Estados)	9
3.6.5 Integración de Características HRV	9
3.7 Estrategia de Evaluación y Validación Cruzada	9
4 Resultados y Discusión	11
4.1 Evaluación cuantitativa de los modelos	11
4.2 Análisis de resultados y discusión	12
4.2.1 El impacto de la atención de canales (Squeeze-and-Excitation)	12
4.2.2 Dificultades de convergencia en el CNN-Transformer Híbrido	12
4.2.3 Modelos de Espacio de Estados (Mamba 1D) y su Capacidad de Generalización	12
4.2.4 El fenómeno del desplazamiento de dominio (Domain Shift)	13
4.3 Comparación con trabajos relacionados	13

5 Conclusiones	14
5.1 Resumen y aportaciones del proyecto	14
5.2 Cumplimiento de objetivos	14
5.3 Valoración crítica y limitaciones	14
5.4 Líneas futuras	14
Referencias	15
Anexos	16
A Ejemplos de uso de $\text{\LaTeX}$	17
A.1 Ecuaciones matemáticas	17
A.1.1 Ecuaciones en línea y display	17
A.1.2 Ecuaciones numeradas	17
A.1.3 Sistemas de ecuaciones	17
A.2 Tablas	17
A.2.1 Tabla simple	17
A.2.2 Tabla con multirow y multicolumn	18
A.2.3 Tabla con datos de resultados	18
A.3 Figuras e imágenes	18
A.3.1 Figura simple	18
A.3.2 Subfiguras	18
A.4 Código y contenido estructurado	19
A.4.1 Listado de texto estructurado	19
A.5 Algoritmos y procedimientos	19
A.5.1 Algoritmo de ejemplo	19
A.6 Referencias cruzadas y citas bibliográficas	20
A.6.1 Referencias cruzadas	20
A.6.2 Citas bibliográficas	20
A.6.3 Cambiar el estilo bibliográfico	21
A.7 Encabezados y pies de página	22
A.8 Referencias cruzadas inteligentes con cleveref	22
A.9 Glosarios y acrónimos	22
A.9.1 Definir acrónimos y términos	22
A.9.2 Usar en el texto	23
A.10 Comandos personalizados útiles	23
A.11 Configuración de colores en hipervínculos	23

Índice de figuras

1.1	Ejemplo de fibrilación auricular, obtenida de (mayo)[https://www.mayoclinic.org/diseases-conditions/atrial-fibrillation/symptoms-causes/syc-20350624]	1
A.1	Ejemplo de figura simple	19
A.2	Ejemplo de figura con subfiguras	19

Índice de cuadros

2.1	Resumen comparativo de las 5 bases de datos de estudio	5
4.1	Resultados comparativos de rendimiento de las arquitecturas en validación y test	11
A.1	Comparación de opciones	18
A.2	Ejemplo de tabla con celdas combinadas	18
A.3	Resultados bajo diferentes escenarios	18

Listings

A.1	Ejemplo de contenido estructurado	19
A.2	Configuración del estilo bibliográfico	21
A.3	Ejemplos de uso de cleveref	22
A.4	Definición de acrónimos y glosario	22
A.5	Uso de acrónimos y glosario en el texto	23

Capítulo 1

Introducción

La Fibrilación Auricular (FA) es la arritmia cardíaca más común, caracterizada por una activación eléctrica auricular caótica. Esta patología provoca una pérdida de la contracción auricular efectiva, que hace que incremente el riesgo de formación de trombos, ictus, insuficiencia cardíaca y deterioro cognitivo a largo plazo??.




Figura 1.1: Ejemplo de fibrilación auricular, obtenida de (mayo)[<https://www.mayoclinic.org/diseases-conditions/atrial-fibrillation/symptoms-causes/syc-20350624>]

Dentro de sus variantes, está la Fibrilación Auricular Paroxística (PAF, por sus siglas en inglés, *Paroxysmal Atrial Fibrillation*). Se define por episodios arrítmicos que se inician de forma espontánea y que vuelven al ritmo sinusal en un periodo que suele ser menor a 7 días, aunque la mayoría lo hacen en menos de 24 horas.

Debido a esta intermitencia, las monitorizaciones ECG de corta duración no suelen lograr capturar los episodios, haciendo de especial interés alguna herramienta de predicción temprana.

Por ello la detección temprana, o en concreto, la predicción inminente de estos episodios, es decir, tener la capacidad de predecir si un paciente sufrirá un episodio en los próximos minutos a partir de su ritmo sinusal, es un área de investigación de especial interés.

Predecir un episodio con una ventana de antelación de hasta 5 minutos proporcionaría una opor-

tunidad terapéutica crucial, permitiendo alertar al paciente para que cese actividades de riesgo, automatizar la administración preventiva de fármacos antiarrítmicos o preparar dispositivos de estimulación eléctrica cardíaca adaptativa.

Tener la capacidad de adelantarnos hasta 5 minutos a un episodio nos daría la capacidad de prevenir, o al menos reducir el riesgo, permitiendo alertar al paciente, para que pueda tomar medidas preventivas, como cesar actividades de riesgo o administrar fármacos antiarrítmicos.

Sin embargo, la predicción es una tarea compleja. La fase previa al episodio es de ritmo sinusal, por lo que a simple vista no se observan patrones evidentes.

Este trabajo aborda el problema de la predicción inminente de PAF mediante redes neuronales. Para garantizar la robustez clínica y la capacidad de generalización de las soluciones propuestas, se unifican cinco bases de datos heterogéneas, comparando cuatro arquitecturas de redes neuronales.

1.1 Contexto del Trabajo

Clásicamente, la predicción de episodios cardíacos se ha abordado mediante la extracción manual de parámetros de Variabilidad del Ritmo Cardíaco (HRV, *Heart Rate Variability*) y la aplicación de clasificadores lineales. Si bien estas métricas ofrecen información valiosa del equilibrio del sistema nervioso autónomo sobre el nodo sinusal, son incapaces de capturar las distorsiones morfológicas locales de las ondas del ECG (como cambios finos en la onda P o en el intervalo PR) que a menudo preceden a la FA.

Estas ofrecen información valiosa sobre el sistema nervioso autónomo, pero son incapaces de capturar las sutiles distorsiones de las ondas (como cambios finos en la onda P o en el intervalo PR) que suelen preceder al episodio de fibrilación auricular.

Las redes neuronales han revolucionado este campo, permitiendo a las redes convolucionales y de atención extraer representaciones directamente a partir de la señal de ECG cruda (*end-to-end*). No obstante, la mayoría de los estudios del estado del arte presentan dos limitaciones críticas:

1. **Sesgo de Base de Datos:** Se entrenan utilizando una única base de datos. Esto genera modelos altamente sobreajustados a las condiciones de ruido y hardware de esa base de datos concreta, que fracasan al ser validados en registros independientes.
2. **Data Leakage y validaciones débiles:** Con frecuencia se comparten ventanas del mismo paciente entre los conjuntos de entrenamiento y test, reportando precisiones artificialmente altas pero clínicamente inutilizables.

Este trabajo se enfoca en resolver estas limitaciones utilizando un dataset consolidado masivo multi-sujeto procedente de sensores hospitalarios de larga duración y dispositivos inteligentes, evaluando los modelos mediante una validación cruzada inter-sujeto estricta.

Este trabajo aborda estas limitaciones, incorporando múltiples bases de datos, y evaluando los modelos mediante una validación cruzada inter-sujeto estricta, asegurando que no se compartan ventanas del mismo paciente entre los conjuntos de entrenamiento y test.

1.2 Objetivos del Proyecto

El objetivo de este proyecto es **diseñar, implementar y evaluar un sistema capaz de predecir de forma inminente (en una ventana de 5 minutos antes del inicio) episodios de Fibrilación Auricular Paroxística (PAF) a partir de segmentos de 10 segundos de señal ECG en ritmo sinusal.**

Para alcanzar este fin, se definen los siguientes objetivos específicos:

- **Objetivo 1:** Integrar cinco bases de datos heterogéneas de PhysioNet: *afpdb*, *cpSC2021*, *Itafdb*, *shdb-af* y *afdb*.
- **Objetivo 2:** Desarrollar un pipeline de preprocesamiento que permita la extracción de ventanas variables de ritmo sinusal Pre-PAF y de características temporales y frecuenciales de HRV.
- **Objetivo 3:** Entrenar cuatro arquitecturas de redes neuronales convolucionales y secuenciales 1D: ResNet 1D (modelo base residual), SEResNet 1D (con atención por canal Squeeze-and-Excitation), un modelo CNN-Transformer (*multi-head self attention*) y Mamba 1D (basado en *state space models*).
- **Objetivo 4:** Integrar la información de HRV mediante una cabeza clasificatoria (Multi-Layer Perceptron) que potencie la toma de decisiones de las redes.
- **Objetivo 5:** Evaluar rigurosamente los modelos bajo un diseño GroupKFold para mitigar la filtración de datos.

Capítulo 2

Datos

La adquisición de datos de calidad es fundamental para el desarrollo de modelos capaces de predecir con generalidad y fiabilidad. Por ello se han incorporado varias bases de datos obtenidas de fuentes públicas, en concreto, de los repositorios de PhysioNet. Estas bases de datos contienen registros de electrocardiogramas (ECG) con anotaciones sobre episodios de fibrilación auricular paroxística (PAF).

2.1 Bases de datos utilizadas

Para el desarrollo de este proyecto se han empleado 5 bases de datos detalladas a continuación:

2.1.1 PAF Prediction Challenge Database (afpdb)

Esta base de datos [1] fue diseñada para el PhysioNet Challenge de predicción de Fibrilación Auricular Paroxística. Contiene registros de ECG de dos canales con una duración de 30 minutos y una frecuencia de muestreo de 128 Hz. El conjunto de aprendizaje consta de 50 parejas de registros (100 registros en total) procedentes de 48 sujetos:

- **Registros tipo 'n':** 50 registros procedentes de sujetos sanos o sin antecedentes de Fibrilación Auricular.
- **Registros tipo 'p':** 50 registros obtenidos inmediatamente antes de un episodio de Fibrilación Auricular (Pre-PAF).

Adicionalmente, existe un conjunto de test con otros 100 registros procedentes de 50 sujetos, que utilizaremos para compararnos con otros trabajos publicados.

2.1.2 China Physiological Signal Challenge 2021 (cpssc2021)

Esta base de datos [2] contiene 1425 registros de 105 sujetos, dos canales, muestreadas a 200 Hz. Contiene anotaciones de ritmo, en concreto, de inicio y fin de episodios de Fibrilación Auricular.

2.1.3 Long-Term Atrial Fibrillation Database (ltafdb)

Esta base de datos [3] contiene registros de ECG ambulatorio de larga duración (aproximadamente 24 horas por registro), grabados a una frecuencia de muestreo de 128 Hz. Consta de 84 registros de 84 sujetos con fibrilación auricular paroxística o sostenida.

2.1.4 Smart Health Devices - Atrial Fibrillation Database (shdb-af)

Esta base de datos [4] proporciona señales de ECG de dos canales registradas mediante dispositivos wearables en condiciones cotidianas. Consta de 128 registros de larga duración (24 horas) procedentes de 122 sujetos con PAF, muestreados originalmente a 125 Hz y resampleados a 200 Hz. Nos proporciona la asignación entre señal y sujeto para prevenir filtraciones (leakage)

2.1.5 MIT-BIH Atrial Fibrillation Database (afdb)

Esta base de datos [5] consta de 25 registros de ECG de dos canales con una duración de 10 horas cada uno, grabados a 250 Hz. Cabe destacar que de 25, 23 de estos registros contienen señales de ECG utilizables, ya que los otros 2 constan únicamente de anotaciones.

2.2 Características comparativas de los conjuntos de datos

A continuación se presenta una tabla 2.1 que resume las características de las 5 bases de datos utilizadas en este proyecto, incluyendo el número de pacientes, el número de registros, el número de canales y la frecuencia de muestreo de cada base de datos.

Cuadro 2.1: Resumen comparativo de las 5 bases de datos de estudio

Base de datos	Nº Pacientes	Nº Registros	Canales	Frec. Muestreo
afpdb [1]	48 (98)	100 (300)	2	128 Hz
cpssc2021 [2]	105	1425	2	200 Hz
ltafdb [3]	84	84	2	128 Hz
shdb-af [4]	122	128	2	200 Hz
afdb [5]	25	25 (23)	2	250 Hz

Nota: Para afpdb, entre paréntesis se indica el total incluyendo el conjunto de test. Para afdb, entre paréntesis se indica el número de registros que contienen señales utilizables.

Capítulo 3

Metodología

A continuación se detallan los métodos que se han seguido para la descarga, preprocesamiento de las señales, extracción de características de variabilidad de ritmo cardíaco (HRV), y las arquitecturas de las redes neuronales utilizadas para la predicción de Fibrilación Auricular a partir de segmentos de ECG en ritmo sinusal.

3.1 Descarga y lectura de bases de datos

La descarga de bases de datos se ha realizado desde el Cluster del Instituto de Investigación en Ingeniería de Aragón (I3A), en concreto, en el grupo de investigación BSICoS, utilizando el gestor de descargas wget.

Para la lectura, se ha utilizado la librería `wfdb` de Python, que permite leer los registros ECG y extraer las anotaciones correspondientes. Puesto que el trabajo se centra en la predicción inminente, se han extraído ventanas inmediatamente anteriores a los episodios de fibrilación auricular (Pre-PAF), en concreto, de un máximo de 5 minutos anteriores al episodio, además de segmentos de control de ritmo sinusal estable.

Cada registro se ha cargado en memoria como un array de `NumPy` para su posterior procesamiento.

3.2 Preprocesamiento

El preprocesamiento es esencial por varias razones: las bases de datos utilizadas no presentan la misma frecuencia de muestreo, ni están medidas con el mismo equipo, por tanto hay que implementar un pipeline que unifique las características para que los modelos puedan generalizar correctamente. El pipeline de preprocesamiento consta de tres pasos principales:

1. **Armonización de Canales y Frecuencia de Muestreo:** Se unifican todas las señales a exactamente dos canales y una frecuencia de muestreo de 128 Hz. Si un registro posee menos de dos canales, se realiza un relleno (padding) con ceros; si posee más, se seleccionan únicamente las dos primeras derivaciones. En nuestro caso todas las bases de datos contienen 2 canales, pero se comprueba por generalidad, para tener la posibilidad de añadir posteriormente bases de datos adicionales. El remuestreo se ejecuta mediante interpolación trigonométrica.
2. **Atenuación del Ruido e Interferencia:** La eliminación del ruido remanente se delega en las primeras capas convolucionales del modelo, que aprenden filtros adaptativos optimizados para la tarea.

3. **Normalización Z-score Local:** Para evitar sesgos debido a las variaciones inter-sujeto o inter-dispositivo en la amplitud absoluta de las señales, cada segmento se normaliza de forma independiente por canal en el dataloader aplicando:

$$x_{\text{norm}} = \frac{x - \mu}{\sigma + 10^{-8}}$$

donde μ y σ representan la media y desviación estándar de la amplitud de cada ventana.

3.3 Extracción de Ventanas y Prevención de Data Leakage

El pipeline procesa los registros de manera dinámica para extraer los dos tipos de segmentos requeridos para la clasificación binaria:

- **Clase 1 (Pre-PAF):**

Esta clase corresponde al estado inmediatamente anterior al inicio de un episodio de fibrilación auricular. Para la extracción de las ventanas, se ha optado por extraer ventanas de longitud variable, de entre 10 segundos y 5 minutos (300 segundos) previos al episodio. La ventana retrocede en el tiempo hasta encontrarse con el inicio del registro o el final del episodio arrítmico previo, garantizando que el segmento contenga únicamente ritmo sinusal.

- **Clase 0 (Normal/Control):** Se extraen segmentos estables de ritmo sinusal de 5 minutos de duración, que se encuentren alejados al menos 30 minutos (1800 segundos) de cualquier episodio (tanto antes como después), evitando zonas de transición.

Esto es importante, ya que estamos extrayendo ventanas de clase normal de pacientes tanto con PAF como sanos.

Esta estrategia es fundamental para evitar el sesgo de clasificación inter-sujeto. Si la Clase 0 se compusiera únicamente de individuos sanos, los modelos tenderían a clasificar diferencias morfológicas asociadas a la cardiopatía estructural del paciente (cardiopatía de fondo) en lugar de identificar los cambios transitorios que desencadenan el episodio. Al incluir el ritmo sinusal basal del propio paciente como control, se garantiza que el modelo aprenda a predecir la transición temporal hacia la arritmia.

Para evitar la filtración de datos (*data leakage*), que invalidaría los resultados, los segmentos se agrupan estrictamente por sujeto. Esto garantiza que en validación y test no haya pacientes que ya hayan aparecido en el entrenamiento, ya que el modelo podría aprender a reconocer la morfología de un paciente concreto en lugar de aprender a generalizar la predicción de la fibrilación auricular.

3.4 Aumento de Datos (Data Augmentation)

Debido a que los modelos escalan mejor con grandes cantidades de datos, se ha implementado un pipeline de aumento de datos, que aplica modificaciones realistas a las señales directamente en el dataloader con una probabilidad del 50 % para cada una:

- **Deriva de la Línea de Base (*Baseline Wander*):** Se simula la deriva lenta causada por la respiración del paciente sumando una señal sinusoidal:

$$x_{\text{aug}}(t) = x(t) + A \cdot \sin(2\pi \cdot f \cdot t)$$

donde la frecuencia f se muestrea de manera uniforme en $[0,1, 0,5]$ Hz y la amplitud A en $[0,05, 0,2]$.

- **Ruido Gaussiano Aditivo:** Se simula el ruido instrumental sumando ruido blanco gaussiano con una desviación estándar variable $\sigma_{\text{noise}} \sim U(0,01, 0,05)$.
- **Escalado Aleatorio:** Se multiplica el segmento por un factor de escala $s \sim U(0,85, 1,15)$ para simular fluctuaciones en la ganancia del amplificador.
- **Slice Aleatorio de Ventana:** Dado que las redes se entrenan con ventanas de 10 segundos, y contamos con señales de hasta 5 minutos, se extraen 10 segundos aleatorios. En validación y test, se toma de forma determinista los últimos 10 segundos (el instante más cercano al inicio de la crisis en la Clase 1).

3.5 Extracción de Variabilidad del Ritmo Cardíaco (HRV)

Como información complementaria, se extraen nueve variables clásicas de variabilidad del ritmo cardíaco (HRV) a partir de los intervalos RR (detectados mediante las anotaciones de los picos QRS originales rescalados a 128 Hz):

- **Métricas Temporales:** Media de los intervalos RR (`mean_rr`), desviación estándar de los intervalos RR (`std_rr`), raíz cuadrada de la media de las diferencias al cuadrado de intervalos RR sucesivos (`rmssd`), porcentaje de intervalos sucesivos que difieren en más de 50 ms (`pnn50`), media de la frecuencia cardíaca instantánea (`mean_hr`) y su desviación estándar (`std_hr`).
- **Métricas Frecuenciales:** Energía en baja frecuencia (`lf`, 0,04 – 0,15 Hz), energía en alta frecuencia (`hf`, 0,15 – 0,4 Hz) obtenidas por el método de Welch, y la relación de balance autonómico (`lf_hf_ratio`).

Estas características se normalizan globalmente utilizando la media y desviación estándar del conjunto de entrenamiento de referencia antes de ser introducidas en el modelo.

3.6 Arquitecturas de Aprendizaje Profundo

Se proponen cuatro arquitecturas para procesar la señal de entrada $\mathbf{X} \in \mathbb{R}^{2 \times L}$ (donde $L = 1280$ muestras para una ventana de 10 segundos a 128 Hz):

3.6.1 ResNet 1D (Baseline)

Basada en bloques convolucionales 1D residuales. Cada bloque residual consta de capas convolucionales seguidas de normalización (*Batch Normalization*), activación ReLU y una *skip connection* que suma la entrada original a la salida del bloque, facilitando el flujo del gradiente en arquitecturas profundas.

3.6.2 SEResNet 1D (Atención de Canales)

Añade bloques *Squeeze-and-Excitation* (SE) tras cada bloque residual. El bloque SE comprime la información espacial del canal mediante un *Global Average Pooling* y, a través de una pequeña red *fully connected* con cuello de botella, calcula un peso de excitación para cada canal. Esto permite a la red ponderar la importancia relativa de cada una de las dos derivaciones del ECG de forma dinámica.

3.6.3 CNN-Transformer Híbrido

Combina las fortalezas de las redes convolucionales y los mecanismos de atención. Las capas convolucionales iniciales extraen rasgos morfológicos locales y reducen la dimensión temporal de la secuencia. Posteriormente, el Transformer procesa la secuencia resultante. Utilizando mecanismos de *Multi-Head Self-Attention*, el Transformer captura relaciones de largo alcance y dependencias temporales complejas a lo largo de todo el segmento de ECG.

3.6.4 Mamba 1D (Modelo de Espacio de Estados)

Como alternativa al Transformer, se implementa una arquitectura basada en *State space models* (SSM) de selección variable (Mamba). Mamba parametriza un sistema lineal invariante en el tiempo que procesa la señal a través de una recurrencia lineal selectiva y dependiente de los datos. Esto permite capturar dependencias de largo alcance con una complejidad computacional que escala linealmente $O(L)$ en lugar de cuadrática $O(L^2)$ como ocurre con el Transformer.

3.6.5 Integración de Características HRV

Adicionalmente, las nueve variables normalizadas de HRV se introducen en un perceptrón multicapa (MLP) de dos capas en las cabezas clasificatorias. La representación vectorial resultante se concatena con el vector de características morfológicas extraído por la red (ResNet, SEResNet, Transformer o Mamba) a la salida de su capa de promedio global. Finalmente, esta representación combinada se introduce en una capa lineal clasificadora con activación Softmax para emitir la probabilidad de Pre-PAF.

3.7 Estrategia de Evaluación y Validación Cruzada

Dado el fuerte desbalance de clases a favor de la clase Pre-PAF tras el proceso de aumentación, y la heterogeneidad de los datos, el diseño experimental se define mediante:

- **Validación Cruzada (5-Fold GroupKFold):** El dataset total se divide en 5 *folds* de forma que todos los segmentos de un mismo paciente queden en el mismo *fold*. En cada iteración, se entrenan los modelos en 4 *folds* y se validan en el restante.
- **Evaluación Externa:** Para comparar los modelos en igualdad de condiciones con la literatura científica, los modelos se evalúan adicionalmente en el conjunto de prueba independiente de la base de datos *afpdb* (PAF Prediction Challenge).

- **Métricas de Calidad:** Se evalúa el rendimiento utilizando la sensibilidad (Recall), especificidad, precisión, puntuación F1 macro (F1 Macro), F1 de la clase Pre-PAF (F1 Clase 1) y el área bajo la curva ROC (AUC-ROC).

Capítulo 4

Resultados y Discusión

En este capítulo se presentan y discuten los resultados obtenidos por las cuatro arquitecturas de aprendizaje profundo implementadas (ResNet 1D, SEResNet 1D, el modelo híbrido CNN-Transformer y Mamba 1D). El entrenamiento y ajuste se han realizado mediante una estrategia de validación cruzada por grupos (5-Fold Group Cross-Validation) sobre el dataset consolidado y aumentado, asegurando que los registros de un mismo sujeto nunca se compartan entre los pliegues de entrenamiento y validación. Finalmente, la capacidad de generalización se evalúa sobre un conjunto de prueba (test) ciego independiente que abarca muestras de todas las bases de datos armonizadas, complementado con la evaluación en el conjunto de test oficial del PhysioNet Challenge.

4.1 Evaluación cuantitativa de los modelos

El rendimiento de los modelos se evalúa a través de métricas estándar de clasificación binaria: exactitud global (Accuracy), precisión, sensibilidad (Recall) y la puntuación F1 (F1-score) tanto por clase como promedio (Macro F1). Los resultados cuantitativos obtenidos en la validación cruzada por grupos y en el conjunto de prueba independiente se detallan en la Tabla 4.1.

Cuadro 4.1: Resultados comparativos de rendimiento de las arquitecturas en validación y test

Modelo	Split	F1 Clase 0	F1 Clase 1	F1 Macro	Accuracy
ResNet 1D	Validación (CV)	—	—	$0,7547 \pm 0,06$	$0,7823 \pm 0,06$
	Test	0.71	0.73	0.72	0.72
SENet 1D	Validación (CV)	—	—	$0,7658 \pm 0,04$	$0,7920 \pm 0,04$
	Test	0.76	0.81	0.79	0.79
Transformer	Validación (CV)	—	—	$0,7550 \pm 0,05$	$0,7752 \pm 0,05$
	Test	0.70	0.67	0.68	0.68
Mamba 1D	Validación (CV)	—	—	$0,7138 \pm 0,09$	$0,7350 \pm 0,09$
	Test	0.75	0.74	0.75	0.75

Nota: La Clase 0 corresponde a Ritmo Sinusal (Normal/Distant) y la Clase 1 a la ventana crítica anterior a la Fibrilación Auricular (Pre-PAF).

Analizando los resultados obtenidos en el conjunto de test, se observa que la arquitectura **SEResNet 1D** (con atención de canales) es el modelo más robusto, logrando una *accuracy* global del 79 % y un F1 Macro del 79 %. En la detección de la clase crítica Pre-PAF (Clase 1), la SEResNet 1D obtiene un F1-score del 81 %, superando a la ResNet 1D (73 %) y al modelo híbrido CNN-Transformer (67 %).

Por su parte, el modelo **Mamba 1D** se consolida como la segunda mejor arquitectura, logrando un F1 Macro del 75 % con un equilibrio entre la detección de ritmo normal (F1 de 75 %) y ritmo pre-arritmico (F1 de 74 %). Esto supera en +3 puntos de F1 Macro a la ResNet 1D convencional y en +7 puntos al CNN-Transformer, confirmando la solidez de los *State Space Models* para señales biológicas.

4.2 Análisis de resultados y discusión

La comparación de los modelos entrenados revela conclusiones sobre el diseño de redes neuronales para señales biomédicas:

4.2.1 El impacto de la atención de canales (Squeeze-and-Excitation)

La superioridad del modelo **SENet 1D** sobre la **ResNet 1D** convencional se debe a la introducción del bloque de atención por canal. Dado que el dataset combina señales de múltiples bases de datos, los registros presentan una gran variabilidad en cuanto a instrumentación o posición de electrodos.

La atención por canal permite al modelo recalibrar dinámicamente la importancia de cada una de las dos derivaciones del ECG de forma adaptativa. Esto ayuda a atenuar el ruido de derivaciones menos informativas y a enfocarse en los canales que presentan las firmas biológicas previas a la PAF (como las variaciones de la morfología de la onda P y las variaciones de HRV), logrando una mejora neta de +8 puntos porcentuales en el F1-score de la clase crítica (del 73 % al 81 %) en comparación con la ResNet base.

4.2.2 Dificultades de convergencia en el CNN-Transformer Híbrido

Aunque el mecanismo de *self attention* temporal del Transformer teóricamente captura dependencias a largo plazo de forma muy eficaz, en este problema clínico la señal de entrada al modelo tiene una duración de 10 segundos. En ventanas temporales tan pequeñas, la morfología local y las transiciones rápidas de ritmo juegan un papel más determinante que la información de contexto a largo plazo. Además, los Transformers requieren un volumen masivo de datos para converger adecuadamente sin sobreajustar, lo que explica la caída de su rendimiento en el conjunto de test en comparación con la validación.

4.2.3 Modelos de Espacio de Estados (Mamba 1D) y su Capacidad de Generalización

La arquitectura **Mamba 1D** presenta un rendimiento sólido, obteniendo un F1 Macro del 75 % en el conjunto de test (con un F1 Clase 0 del 75 % y F1 Clase 1 del 74 %). Esto posiciona a Mamba 1D como la segunda mejor arquitectura en cuanto a generalización global, superando a la ResNet 1D base (+3 puntos porcentuales de F1 Macro) y al CNN-Transformer Híbrido (+7 puntos de F1 Macro), aunque quedando por detrás de la SENet 1D (79 % F1 Macro).

El éxito de Mamba 1D se puede deber a su capacidad de procesar las dependencias temporales de la señal a través de un mecanismo de selección recurrente lineal variable que escala linealmente $O(L)$ en lugar de la *self attention* cuadrática $O(L^2)$ del Transformer. Al evitar el sobreajuste masivo que sufren los Transformers en conjuntos de datos medianos, Mamba conserva gran parte de la información de largo alcance sin penalizar su capacidad de generalización en test. Sin embargo, su desempeño por debajo de

la SENet 1D nos puede indicar que la atención específica a nivel de derivación física (atención de canales) provista por los bloques Squeeze-and-Excitation sigue siendo la estrategia más eficiente para lidiar con el ruido espacial e instrumental característico de las señales multicanal de ECG.

4.2.4 El fenómeno del desplazamiento de dominio (Domain Shift)

Un hallazgo clave de este trabajo es la discrepancia observada entre el rendimiento en el conjunto de prueba general y las puntuaciones en el reto oficial de PhysioNet (afpdb):

- Originalmente se fué mas estricto a la hora de extraer ventanas, asumiendo que si no se encontraban 5 minutos completos, no se consideraba. Esto dejó a la base de datos afpdb como una fuente altamente representativa, y por ello los modelos obtenían puntuaciones altas en el reto (hasta 79 % en el CNN-Transformer y 75 % en la ResNet 1D), pero a costa de un F1-score muy bajo en condiciones generales (56 % y 61 % respectivamente).
- Tras realizar el aumento de datos mediante ventanas variables, el volumen de la base de datos del reto (afpdb) pasa a representar solo el 1.2 % del total de Clase 1 en el entrenamiento, que ahora es dominado por registros de Holter ambulatorio de 24 horas (1tafdb) y dispositivos corporales inteligentes (shdb-af).
- Como consecuencia directa, la generalización clínica ante nuevos sujetos mejora notablemente (alcanzando el 81 % de F1 Pre-PAF en la SEResNet 1D), pero las puntuaciones del reto específico se sitúan en 64 % para la SEResNet 1D, 61 % para el CNN-Transformer, 54 % para el Mamba 1D y 50 % para la ResNet 1D.

Al optimizar los modelos con un dataset más grande, diverso y realista, las redes aprenden a priorizar rasgos generales de ECG ambulatorio y wearables. Sin embargo, esto diluye la especialización del modelo a la base de datos afpdb original.

4.3 Comparación con trabajos relacionados

La mayoría de los algoritmos publicados en la literatura científica que evalúan su rendimiento en el PhysioNet Challenge de predicción de PAF entrenan y validan sus modelos únicamente utilizando los datos de la base de datos afpdb, o de bases de datos específicas. Aunque muchos logran clasificaciones sobresalientes en este benchmark específico (79 % de precisión), carecen de la generalidad que ofrecen estos modelos.

Este trabajo demuestra que el entrenamiento exclusivo sobre una única base de datos induce un sesgo de adquisición artificial. Al contrastar nuestros modelos con una validación cruzada inter-sujeto sobre cinco bases de datos, demostramos la viabilidad de un predictor de PAF generalizable capaz de mantener una alta sensibilidad y especificidad incluso en señales capturadas por wearables en condiciones cotidianas.

Capítulo 5

Conclusiones

A continuación, se presentan las conclusiones finales del proyecto planteando las futuras líneas de investigación.

5.1 Resumen y aportaciones del proyecto

Las principales contribuciones incluyen:

- La consolidación de cinco bases de datos heterogéneas (afpdb, cpsc2021, ltafdb, shdb-af y afdB) en un único formato.
- La prevención de filtrado de información (data leakage) aplicando una separación de conjuntos de datos agrupando por paciente.
- La comparación del rendimiento de modelos convolucionales tradicionales frente a arquitecturas residuales avanzadas (SEResNet) con *self-attention* de canales.

5.2 Cumplimiento de objetivos

Se han alcanzado los objetivos iniciales planteados...

5.3 Valoración crítica y limitaciones

A pesar de la alta capacidad de clasificación, el problema presenta desafíos debido a la variabilidad de la señal ECG en diferentes pacientes y el ruido inherente a los dispositivos de registro ambulatorio.

5.4 Líneas futuras

Como extensiones naturales al trabajo realizado, se proponen las siguientes líneas de desarrollo futuro:

- **Exploración de Modelos de Lenguaje para Señales (Signal Transformers):** Investigar arquitecturas avanzadas auto-supervisadas preentrenadas en grandes corpus de datos ECG.
- **Optimización de Hyperparámetros en SEResNet:** Refinar el ratio de reducción en los bloques Squeeze-and-Excitation.
- **Despliegue e integración clínica:** Probar el clasificador en sistemas integrados de monitoreo en tiempo real.

Referencias

- [1] G. B. Moody, A. L. Goldberger, S. McClennen y S. P. Swiryn, *PAF Prediction Challenge Database*, 2001. DOI: [10.13026/C2H59W](https://doi.org/10.13026/C2H59W) dirección: <https://physionet.org/content/afpdb/>
- [2] X. Wang, C. Ma, X. Zhang, H. Gao, G. D. Clifford y C. Liu, "Paroxysmal Atrial Fibrillation Events Detection from Dynamic ECG Recordings: The 4th China Physiological Signal Challenge 2021", *PhysioNet*, jun. de 2021, Version 1.0.0. DOI: [10.13026/ksya-qw89](https://doi.org/10.13026/ksya-qw89) dirección: <https://doi.org/10.13026/ksya-qw89>
- [3] S. Petrutiu, A. V. Sahakian y S. Swiryn, *The Long-Term AF Database*, 2003. DOI: [10.13026/C2QG6Q](https://doi.org/10.13026/C2QG6Q) dirección: <https://physionet.org/content/ltafdb/>
- [4] K. Tsutsui, S. Biton Brimer y J. Behar, "SHDB-AF: a Japanese Holter ECG database of atrial fibrillation", *PhysioNet*, abr. de 2025, Version 1.0.1. DOI: [10.13026/n6yq-fq90](https://doi.org/10.13026/n6yq-fq90) dirección: <https://doi.org/10.13026/n6yq-fq90>
- [5] G. B. Moody y R. G. Mark, *MIT-BIH Atrial Fibrillation Database*, 1992. DOI: [10.13026/C2MW2D](https://doi.org/10.13026/C2MW2D) dirección: <https://physionet.org/content/afdb/>
- [6] N. Apellido y N. Apellido, "Título del artículo", *Nombre de la Revista*, vol. 42, n.º 8, págs. 123-145, 2020. DOI: [10.1234/ejemplo.2020.123456](https://doi.org/10.1234/ejemplo.2020.123456)
- [7] N. Apellido, N. Apellido y N. Apellido, "Título de la contribución a congreso", en *Actas del Congreso Internacional*, Ciudad, País: Editorial, 2021, págs. 100-110. DOI: [10.1234/ejemplo.2021.654321](https://doi.org/10.1234/ejemplo.2021.654321)
- [8] N. Apellido, *Título del libro*, 3.ª ed. Editorial, 1997, ISBN: 978-0123456789.
- [9] Nombre de la Organización. "Título del recurso en línea", Nombre de la Organización, visitado 15 de ene. de 2024. dirección: <https://www.ejemplo.org/recurso>
- [10] Nombre del Organismo, "Título del informe técnico", Nombre de la Institución, Ciudad, País, Informe, 2001.

Anexos

Apéndice A

Ejemplos de uso de $\text{\LaTeX}$

Este anexo contiene ejemplos de los principales elementos de $\text{\LaTeX}$ utilizados en documentos académicos. Sirve como referencia rápida para usuarios de esta plantilla.

A.1 Ecuaciones matemáticas

A.1.1 Ecuaciones en línea y display

Las ecuaciones pueden aparecer en línea como $E = mc^2$ o en modo display:

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}$$

A.1.2 Ecuaciones numeradas

Para ecuaciones numeradas se utiliza el entorno `equation`:

$$y = mx + b \tag{A.1}$$

La ecuación (A.1) representa un ejemplo de ecuación numerada que puede ser referenciada en el texto.

A.1.3 Sistemas de ecuaciones

Para sistemas de ecuaciones se puede usar `align`:

$$a_1x + b_1y = c_1 \tag{A.2}$$

$$a_2x + b_2y = c_2 \tag{A.3}$$

$$a_3x + b_3y = c_3 \tag{A.4}$$

Las ecuaciones (A.2)–(A.4) muestran cómo alinear múltiples ecuaciones.

A.2 Tablas

A.2.1 Tabla simple

La tabla A.1 muestra un ejemplo básico usando el paquete `booktabs`.

Cuadro A.1: Comparación de opciones

Opción	Métrica 1	Métrica 2
Opción A	Alto	Baja
Opción B	Medio	Alta
Opción C	Variable	Media

A.2.2 Tabla con multirow y multicolumn

La tabla A.2 ilustra el uso de celdas combinadas con `multirow` y `multicolumn`.

Cuadro A.2: Ejemplo de tabla con celdas combinadas

Configuración	Medida 1		Medida 2	
	Media	Desv. Est.	Media	Desv. Est.
Config A	45.2	3.1	1200	85
Config B	38.7	2.8	1450	92
Config C	52.1	4.2	980	73

A.2.3 Tabla con datos de resultados

La tabla A.3 muestra un ejemplo de tabla de resultados experimentales.

Cuadro A.3: Resultados bajo diferentes escenarios

Escenario	Variable 1 (unidades)	Variable 2 (unidades)	Variable 3 (unidades)	Variable 4 (unidades)	Variable 5 (%)
Escenario A	50	10	450	35	0.1
Escenario B	200	15	1650	78	0.3
Escenario C	500	20	3200	142	1.2
Escenario D	1000	5	4500	310	3.5

A.3 Figuras e imágenes

A.3.1 Figura simple

La figura A.1 muestra un ejemplo básico de figura con caption (puedes descomentar el código de abajo cuando tengas tus imágenes).

A.3.2 Subfiguras

La figura A.2 presenta un ejemplo de subfiguras usando el paquete `subcaption`. Las subfiguras A.2a y A.2b pueden ser referenciadas individualmente.



Figura A.1: Ejemplo de figura simple



(a) Subfigura A



(b) Subfigura B

Figura A.2: Ejemplo de figura con subfiguras

A.4 Código y contenido estructurado

A.4.1 Listado de texto estructurado

El listado [A.1](#) muestra cómo usar el paquete `listings` para contenido estructurado.

```

1 Elemento 1: Descripción del elemento 1
2   Subelemento 1.1: Detalle del subelemento
3   Subelemento 1.2: Detalle del subelemento
4
5 Elemento 2: Descripción del elemento 2
6   Subelemento 2.1: Detalle del subelemento
7   Subelemento 2.2: Detalle del subelemento
8   Subelemento 2.3: Detalle del subelemento
9
10 Elemento 3: Descripción del elemento 3
11   Subelemento 3.1: Detalle del subelemento
12
13 Proceso:
14   Paso 1 -> Paso 2 -> Paso 3

```

Listing A.1: Ejemplo de contenido estructurado

A.5 Algoritmos y procedimientos

A.5.1 Algoritmo de ejemplo

El algoritmo [1](#) muestra cómo usar el paquete `algorithm2e` para describir procedimientos.

Algoritmo 1: Ejemplo de procedimiento genérico**Input:** Entrada: conjunto de elementos $L = \{e_1, e_2, \dots, e_n\}$, parámetro p **Output:** Salida: elemento seleccionado e_i

```

1  $minValor \leftarrow \infty$ ;
2  $elementoSeleccionado \leftarrow null$ ;
3 for cada elemento  $e \in L$  do
4   if  $e.cumpleCondicion()$  then
5      $valor \leftarrow e.calcularValor()$ ;
6     if  $valor < minValor$  then
7        $minValor \leftarrow valor$ ;
8        $elementoSeleccionado \leftarrow e$ ;
9 if  $elementoSeleccionado \neq null$  then
10    $elementoSeleccionado.aplicar(p)$ ;
11   return  $elementoSeleccionado$ ;
12 else
13   return ERROR: No hay elementos válidos;

```

A.6 Referencias cruzadas y citas bibliográficas

A.6.1 Referencias cruzadas

Este anexo demuestra el uso de referencias cruzadas a diferentes elementos del documento:

- Ecuaciones: La ecuación (A.1) muestra una referencia con \eqref
- Tablas: La tabla A.1 usa \ref
- Figuras: La figura A.1 también usa \ref
- Listados: El listado A.1 se referencia igual
- Algoritmos: El algoritmo 1 se referencia de la misma forma

A.6.2 Citas bibliográficas

Cita simple

Para citar una única referencia se usa el comando \cite. Por ejemplo: “Según estudios recientes [6], se ha demostrado que...”

Citas múltiples

Para citar varias referencias juntas se usa \cites. Por ejemplo: “Diversos autores han trabajado en este tema [6, 7], demostrando que...”

Citas con página específica

Para citar una página concreta se añade el número de página como parámetro opcional. Por ejemplo: “Como se menciona en el trabajo de Apellido [7, p. 105], es importante considerar...”

Otras citas de ejemplo

Se pueden combinar diferentes estilos de citas en el texto:

- Referencias de libros [8]
- Referencias de recursos en línea [9]
- Referencias de informes técnicos [10]
- Múltiples citas de diferentes tipos [8-10]

Todas estas citas se gestionan automáticamente con biblatex y biber, generando la lista de referencias al final del documento en formato IEEE.

A.6.3 Cambiar el estilo bibliográfico

Esta plantilla usa el estilo IEEE por defecto. Para cambiar a otro estilo, modifica la línea en el preámbulo:

```
1 % Estilo actual (IEEE)
2 \usepackage[
3   style=ieee,
4   citestyle=numeric-comp,
5   sorting=none,
6   backend=biber
7 ]{biblatex}
8
9 % Ejemplos de otros estilos comunes:
10 % APA (Ciencias Sociales)
11 % style=apa, citestyle=apa
12
13 % Vancouver (Ciencias de la Salud)
14 % style=numeric, citestyle=numeric
15
16 % Chicago (Humanidades)
17 % style=authoryear, citestyle=authoryear
18
19 % Alphanumeric (Orden alfabético)
20 % style=alphanumeric, citestyle=alphanumeric
```

Listing A.2: Configuración del estilo bibliográfico

A.7 Encabezados y pies de página

Esta plantilla usa el paquete `fancyhdr` para personalizar los encabezados. La configuración actual muestra:

- Número de página en el margen exterior (derecha en páginas impares, izquierda en pares)
- Nombre del capítulo en páginas pares
- Nombre de la sección en páginas impares
- Línea horizontal separando el encabezado del contenido

A.8 Referencias cruzadas inteligentes con `cleveref`

Esta plantilla incluye el paquete `cleveref` que permite referencias cruzadas más inteligentes y automáticas. En lugar de escribir manualmente “la figura `\ref{fig:ejemplo1}`”, puedes usar:

```

1 % En lugar de: como se muestra en la figura~\ref{fig:ejemplo1}
2 % Usa: como se muestra en la \cref{fig:ejemplo1}
3 % Resultado: como se muestra en la figura 3.1
4
5 % Para mayuscula al inicio de frase:
6 % \Cref{fig:ejemplo1} muestra un ejemplo
7 % Resultado: Figura 3.1 muestra un ejemplo
8
9 % Referencias multiples automaticas:
10 % Las \cref{fig:ejemplo1,fig:ejemplo2,tab:simple} muestran...
11 % Resultado: Las figuras 3.1, 3.2 y tabla 2.1 muestran...
```

Listing A.3: Ejemplos de uso de `cleveref`

El paquete está configurado para español y reconoce automáticamente figuras, tablas, ecuaciones, capítulos, secciones, listados y algoritmos.

A.9 Glosarios y acrónimos

Esta plantilla incluye soporte para glosarios y listas de acrónimos mediante el paquete `glossaries`.

A.9.1 Definir acrónimos y términos

En el preámbulo del documento, define tus acrónimos y términos:

```

1 % Definir un acronimo
2 \newacronym{http}{HTTP}{Hypertext Transfer Protocol}
3 \newacronym{api}{API}{Application Programming Interface}
4
5 % Definir un termino del glosario
```

```

6 \newglossaryentry{algoritmo}{
7   name=algoritmo,
8   description={Secuencia finita de instrucciones bien definidas
9     para resolver un problema o realizar una tarea}
10 }

```

Listing A.4: Definición de acrónimos y glosario

A.9.2 Usar en el texto

Usa los acrónimos y términos en tu documento:

```

1 % Primera mencion muestra completo: HTTP (HyperText Protocol)
2 % Siguietes menciones solo muestran: HTTP
3 El protocolo \gls{http} permite la transferencia de datos.
4
5 % Forzar forma completa
6 \acrfull{http}
7
8 % Forzar solo acronimo
9 \acrshort{http}
10
11 % Terminos del glosario
12 Un \gls{algoritmo} es fundamental en programacion.

```

Listing A.5: Uso de acrónimos y glosario en el texto

Ejemplo de resultado: Si usas `\gls{tfg}` por primera vez en el texto, aparecerá: “Trabajo Fin de Grado (TFG)”. Las siguientes veces solo mostrará: “TFG”.

A.10 Comandos personalizados útiles

La plantilla incluye algunos comandos personalizados para abreviaturas comunes:

- Varios factores (i.e. temperatura y presión) afectan el resultado del experimento.
- Algunos lenguajes (e.g. Python, Java) son muy populares en la actualidad.
- Según Smith et al. [1], se observa que estos métodos son efectivos.

A.11 Configuración de colores en hipervínculos

Esta plantilla tiene activados colores sutiles en los hipervínculos por defecto para mejorar la navegación del documento:

- **Enlaces internos** (capítulos, secciones, figuras, tablas): azul oscuro
- **Citas bibliográficas:** verde oscuro

- **URLs externas:** azul

Para desactivar los colores y usar enlaces ocultos, modifica la configuración de `hyperref` en el preámbulo.