



**Universidad
Zaragoza**

Trabajo Fin de Grado

Predicción de fibrilación auricular paroxística a partir
del electrocardiograma en ritmo sinusal mediante el
análisis con redes neuronales profundas

*Prediction of Paroxysmal Atrial Fibrillation from the
Sinus Rhythm Electrocardiogram Using Deep Neural
Networks*

Autor

Diego Bouchet Agudo

Directores

Juan Pablo Martínez Cortés

Antonio Miguel Artiaga

Titulación

Grado en Ingeniería de Tecnologías y Servicios de Telecomunicación

Escuela de Ingeniería y Arquitectura (EINA)

2026

Resumen

Título del trabajo

Predicción de fibrilación auricular paroxística a partir del electrocardiograma en ritmo sinusal mediante el análisis con redes neuronales profundas

English Title

Prediction of Paroxysmal Atrial Fibrillation from the Sinus Rhythm Electrocardiogram Using Deep Neural Networks

RESUMEN

La Fibrilación Auricular Paroxística (PAF) es una de las arritmias mas comunes caracterizada por latidos irregulares de la aurícula. Su diagnóstico temprano es complejo ya que la naturaleza de la fibrilacion auricular paroxística es intermitente, por lo que la predicción de episodios inminentes a partir de señales ECG en ritmo sinusal es de especial interés. Este trabajo aborda este desafío.

Para asegurar la capacidad de generalización de los modelos, se consolidó un dataset a partir de cinco bases de datos públicas de PhysioNet. Se diseñó un preprocesamiento que extrae ventanas de duración variable previas a los episodios y extrae nueve variables de variabilidad del ritmo cardíaco (HRV). Se implementaron cuatro arquitecturas de red neuronal 1D: ResNet 1D (baseline), SEResNet 1D (con atención de canales), un híbrido CNN-Transformer y Mamba 1D (*selective state space model*). Para evitar la filtración de datos, los experimentos se validaron de forma cruzada agrupando estrictamente por sujeto (5-Fold GroupKFold).

Los resultados en el conjunto de test demuestran la superioridad de la SEResNet 1D con un F1 Macro del 79 % y un F1-score del 81 % en la clase crítica Pre-PAF, seguido por el modelo Mamba 1D con un 75 % de F1 Macro.

Este estudio valida la viabilidad de un sistema generalizable inter-sujeto para la monitorización de alerta temprana de episodios de Fibrilación Auricular Paroxística.

Palabras clave: Fibrilación Auricular Paroxística, Predicción Inminente, Procesamiento de ECG, Aprendizaje Profundo, Variabilidad del Ritmo Cardíaco (HRV), Mamba.

ABSTRACT

Paroxysmal Atrial Fibrillation (PAF) is one of the most common arrhythmias, characterized by irregular heartbeats in the atrium. Its early diagnosis is complex because the nature of paroxysmal atrial fibrillation is intermittent; therefore, predicting imminent episodes from ECG signals in sinus rhythm is of special interest. This work addresses this challenge.

To ensure the models' generalization capability, a dataset was consolidated from five public PhysioNet databases. A preprocessing pipeline was designed to extract variable-duration windows prior to the episodes and extract nine heart rate variability (HRV) variables. Four 1D neural network architectures were implemented: 1D ResNet (baseline), 1D SEResNet (with channel attention), a hybrid CNN-Transformer, and 1D Mamba (selective state space model). To prevent data leakage, the experiments were cross-validated by strictly grouping by subject (5-Fold GroupKFold).

The results on the test set demonstrate the superiority of the 1D SEResNet with a Macro F1 of 79% and an F1-score of 81% in the critical Pre-PAF class, followed by the 1D Mamba model with a 75% Macro F1.

This study validates the feasibility of an inter-subject generalizable system for early warning monitoring of Paroxysmal Atrial Fibrillation episodes.

Keywords: Paroxysmal Atrial Fibrillation, Imminent Prediction, ECG Signal Processing, Deep Learning, Heart Rate Variability (HRV), Mamba.

Índice general

Resumen	I
1 Introducción	1
1.1 Contexto del Trabajo	2
1.2 Objetivos del Proyecto	2
2 Datos	4
2.1 Bases de datos utilizadas	4
2.1.1 PAF Prediction Challenge Database (afpdb)	4
2.1.2 China Physiological Signal Challenge 2021 (cpssc2021)	4
2.1.3 Long-Term Atrial Fibrillation Database (ltafdb)	4
2.1.4 Smart Health Devices - Atrial Fibrillation Database (shdb-af)	5
2.1.5 MIT-BIH Atrial Fibrillation Database (afdb)	5
2.2 Características comparativas de los conjuntos de datos	5
3 Metodología	6
3.1 Descarga y lectura de bases de datos	6
3.2 Preprocesamiento	6
3.3 Extracción de Ventanas y Prevención de Data Leakage	7
3.4 Aumento de Datos (Data Augmentation)	7
3.5 Extracción de Variabilidad del Ritmo Cardíaco (HRV)	8
3.6 Arquitecturas de Aprendizaje Profundo	8
3.6.1 ResNet 1D (Baseline)	8
3.6.2 SEResNet 1D (Atención de Canales)	9
3.6.3 CNN-Transformer Híbrido	9
3.6.4 Mamba 1D (Modelo de Espacio de Estados)	9
3.6.5 Integración de Características HRV	12
3.7 Estrategia de Evaluación y Validación Cruzada	12
4 Resultados y Discusión	13
4.1 Resultados detallados por arquitectura	13
4.1.1 Arquitectura ResNet 1D y variaciones estructurales	13
4.1.2 Arquitectura SEResNet 1D con atención de canales	15
4.1.3 Arquitectura CNN-Transformer Híbrida y variaciones estructurales	16
4.1.4 Arquitectura Mamba 1D y capacidad de representación	17
4.2 Evaluación comparativa inter-modelo	17
4.3 Análisis de resultados y discusión	18

4.3.1	El impacto de la regularización estructural frente a mecanismos de atención . .	18
4.3.2	Superación del Sobreajuste en el CNN-Transformer Híbrido mediante Compresión Dimensional	18
4.3.3	Modelos de Espacio de Estados (Mamba 1D) y su Capacidad de Generalización .	19
4.3.4	Discrepancia entre el rendimiento en test general y el benchmark de PhysioNet .	19
4.4	Comparación con trabajos relacionados	19
5	Conclusiones	21
5.1	Resumen y aportaciones del proyecto	21
5.2	Cumplimiento de objetivos	21
5.3	Valoración crítica y limitaciones	21
5.4	Líneas futuras	21
	Referencias	22
	Anexos	23

Índice de figuras

1.1	Ejemplo de ECG en fibrilación auricular. Imagen obtenida de la Mayo Clinic.	1
3.1	Arquitectura base ResNet 1D. La red procesa la entrada reduciendo progresivamente la dimensión temporal mediante bloques residuales, integrando finalmente las características HRV antes del clasificador <i>fully connected</i>	9
3.2	Arquitectura SEResNet 1D. Tras cada bloque residual se incorpora un módulo Squeeze-and-Excitation que recalibra adaptativamente los pesos de los canales de extracción de características.	10
3.3	Arquitectura híbrida CNN-Transformer. Se utiliza un <i>frontend</i> convolucional para la extracción local y reducción de dimensionalidad, seguido de codificadores posicionales y un <i>Transformer Encoder</i> para la atención global.	10
3.4	Arquitectura híbrida CNN-Mamba. La secuencia latente generada por el <i>frontend</i> convolucional es procesada de forma puramente secuencial mediante bloques SSM selectivos, prescindiendo de codificadores posicionales.	11

Índice de cuadros

2.1	Resumen comparativo de las 5 bases de datos de estudio	5
4.1	Resultados comparativos de las variaciones de la arquitectura ResNet 1D con y sin aumento de datos	14
4.2	Resultados comparativos de las variaciones de la arquitectura SEResNet 1D con y sin aumento de datos	15
4.3	Resultados comparativos de las variaciones de la arquitectura CNN-Transformer 1D con y sin aumento de datos	16
4.4	Resultados comparativos de rendimiento de las mejores variantes de cada arquitectura en validación y test	17

Capítulo 1

Introducción

La Fibrilación Auricular (FA) es la arritmia cardíaca más común, caracterizada por una activación eléctrica auricular caótica (como se ilustra en la Figura 1.1). Esta patología provoca una pérdida de la contracción auricular efectiva, lo que incrementa el riesgo de formación de trombos, accidentes cerebrovasculares (ictus), insuficiencia cardíaca y deterioro cognitivo a largo plazo [1].




Figura 1.1: Ejemplo de ECG en fibrilación auricular. Imagen obtenida de la [Mayo Clinic](#).

Dentro de sus variantes, está la Fibrilación Auricular Paroxística (PAF, por sus siglas en inglés, *Paroxysmal Atrial Fibrillation*). Se define por episodios arrítmicos que se inician de forma espontánea y que vuelven al ritmo sinusal en un periodo que suele ser menor a 7 días, aunque la mayoría lo hacen en menos de 24 horas.

Debido a esta intermitencia, las monitorizaciones ECG de corta duración no suelen lograr capturar los episodios, haciendo de especial interés alguna herramienta de predicción temprana.

Por ello la detección temprana, o en concreto, la predicción inminente de estos episodios, es decir, tener la capacidad de predecir si un paciente sufrirá un episodio en los próximos minutos a partir de su ritmo sinusal, es un área de investigación de especial interés.

Predecir un episodio con una ventana de antelación de hasta 5 minutos proporcionaría una oportunidad terapéutica crucial, permitiendo alertar al paciente para que cese actividades de riesgo, auto-

matizar la administración preventiva de fármacos antiarrítmicos o preparar dispositivos de estimulación eléctrica cardíaca adaptativa.

Sin embargo, la predicción es una tarea compleja. La fase previa al episodio arrítmico se presenta en ritmo sinusal, por lo que a simple vista en el ECG no se observan patrones o anomalías morfológicas evidentes.

Este trabajo aborda el problema de la predicción inminente de PAF mediante redes neuronales. Para garantizar la capacidad de generalización de las soluciones propuestas, se unifican cinco bases de datos heterogéneas, comparando cuatro arquitecturas de redes neuronales.

1.1 Contexto del Trabajo

Clásicamente, la predicción de episodios cardíacos se ha abordado mediante la extracción manual de parámetros de Variabilidad del Ritmo Cardíaco (HRV, *Heart Rate Variability*) y la aplicación de clasificadores lineales. Si bien estas métricas ofrecen información valiosa del equilibrio del sistema nervioso autónomo sobre el nodo sinusal, son incapaces de capturar las distorsiones morfológicas locales de las ondas del ECG (como cambios finos en la onda P o en el intervalo PR) que a menudo preceden a la FA.

Las redes neuronales han revolucionado este campo, permitiendo a las redes convolucionales y de atención extraer representaciones directamente a partir de la señal de ECG cruda (*end-to-end*). No obstante, la mayoría de los estudios del estado del arte presentan dos limitaciones críticas:

1. **Sesgo de Base de Datos:** Se entrenan utilizando una única base de datos. Esto genera modelos altamente sobreajustados a las condiciones de ruido y hardware de esa base de datos concreta, que fracasan al ser validados en registros independientes.
2. **Data Leakage y validaciones débiles:** Con frecuencia se comparten ventanas del mismo paciente entre los conjuntos de entrenamiento y test, reportando precisiones artificialmente altas pero clínicamente inutilizables.

Este trabajo se enfoca en resolver estas limitaciones utilizando un dataset consolidado masivo multi-sujeto procedente de sensores hospitalarios de larga duración y dispositivos inteligentes, evaluando los modelos mediante una validación cruzada inter-sujeto estricta.

1.2 Objetivos del Proyecto

El objetivo de este proyecto es **diseñar, implementar y evaluar un sistema capaz de predecir de forma inminente (en una ventana de 5 minutos antes del inicio) episodios de Fibrilación Auricular Paroxística (PAF) a partir de segmentos de 10 segundos de señal ECG en ritmo sinusal.**

Para alcanzar este fin, se definen los siguientes objetivos específicos:

- **Objetivo 1:** Integrar cinco bases de datos heterogéneas de PhysioNet: *afpdb*, *cpusc2021*, *Itafdb*, *shdb-af* y *afdb*.
- **Objetivo 2:** Desarrollar un pipeline de preprocesamiento que permita la extracción de ventanas variables de ritmo sinusal Pre-PAF y de características temporales y frecuenciales de HRV.

- **Objetivo 3:** Entrenar cuatro arquitecturas de redes neuronales convolucionales y secuenciales 1D: ResNet 1D (modelo base residual), SEResNet 1D (con atención por canal Squeeze-and-Excitation), un modelo CNN-Transformer (*multi-head self attention*) y Mamba 1D (basado en *state space models*).
- **Objetivo 4:** Integrar la información de HRV mediante una cabeza clasificatoria (Multi-Layer Perceptron) que potencie la toma de decisiones de las redes.
- **Objetivo 5:** Evaluar rigurosamente los modelos bajo un diseño GroupKFold para mitigar la filtración de datos.

Capítulo 2

Datos

La adquisición de datos de calidad es fundamental para el desarrollo de modelos capaces de predecir con generalidad y fiabilidad. Por ello se han incorporado varias bases de datos obtenidas de fuentes públicas, en concreto, de los repositorios de PhysioNet. Estas bases de datos contienen registros de electrocardiogramas (ECG) con anotaciones sobre episodios de fibrilación auricular paroxística (PAF).

2.1 Bases de datos utilizadas

Para el desarrollo de este proyecto se han empleado 5 bases de datos detalladas a continuación:

2.1.1 PAF Prediction Challenge Database (afpdb)

Esta base de datos [2] fue diseñada para el PhysioNet Challenge de predicción de Fibrilación Auricular Paroxística. Contiene registros de ECG de dos canales con una duración de 30 minutos y una frecuencia de muestreo de 128 Hz. El conjunto de aprendizaje consta de 50 parejas de registros (100 registros en total) procedentes de 48 sujetos:

- **Registros tipo 'n':** 50 registros procedentes de sujetos sanos o sin antecedentes de Fibrilación Auricular.
- **Registros tipo 'p':** 50 registros obtenidos inmediatamente antes de un episodio de Fibrilación Auricular (Pre-PAF).

Adicionalmente, existe un conjunto de test con otros 100 registros procedentes de 50 sujetos, que utilizaremos para compararnos con otros trabajos publicados.

2.1.2 China Physiological Signal Challenge 2021 (cpssc2021)

Esta base de datos [3] contiene 1425 registros de 105 sujetos, dos canales, muestreadas a 200 Hz. Contiene anotaciones de ritmo, en concreto, de inicio y fin de episodios de Fibrilación Auricular.

2.1.3 Long-Term Atrial Fibrillation Database (ltafdb)

Esta base de datos [4] contiene registros de ECG ambulatorio de larga duración (aproximadamente 24 horas por registro), grabados a una frecuencia de muestreo de 128 Hz. Consta de 84 registros de 84 sujetos con fibrilación auricular paroxística o sostenida.

2.1.4 Smart Health Devices - Atrial Fibrillation Database (shdb-af)

Esta base de datos [5] proporciona señales de ECG de dos canales registradas mediante dispositivos wearables en condiciones cotidianas. Consta de 128 registros de larga duración (24 horas) procedentes de 122 sujetos con PAF, muestreados originalmente a 125 Hz y resampleados a 200 Hz. Nos proporciona la asignación entre señal y sujeto para prevenir filtraciones (leakage)

2.1.5 MIT-BIH Atrial Fibrillation Database (afdb)

Esta base de datos [6] consta de 25 registros de ECG de dos canales con una duración de 10 horas cada uno, grabados a 250 Hz. Cabe destacar que de 25, 23 de estos registros contienen señales de ECG utilizables, ya que los otros 2 constan únicamente de anotaciones.

2.2 Características comparativas de los conjuntos de datos

A continuación se presenta una tabla 2.1 que resume las características de las 5 bases de datos utilizadas en este proyecto, incluyendo el número de pacientes, el número de registros, el número de canales y la frecuencia de muestreo de cada base de datos.

Cuadro 2.1: Resumen comparativo de las 5 bases de datos de estudio

Base de datos	Nº Pacientes	Nº Registros	Canales	Frec. Muestreo
afpdb [2]	48 (98)	100 (300)	2	128 Hz
cpssc2021 [3]	105	1425	2	200 Hz
ltafdb [4]	84	84	2	128 Hz
shdb-af [5]	122	128	2	200 Hz
afdb [6]	25	25 (23)	2	250 Hz

Nota: Para afpdb, entre paréntesis se indica el total incluyendo el conjunto de test. Para afdb, entre paréntesis se indica el número de registros que contienen señales utilizables.

Capítulo 3

Metodología

A continuación se detallan los métodos que se han seguido para la descarga, preprocesamiento de las señales, extracción de características de variabilidad de ritmo cardíaco (HRV), y las arquitecturas de las redes neuronales utilizadas para la predicción de Fibrilación Auricular a partir de segmentos de ECG en ritmo sinusal.

3.1 Descarga y lectura de bases de datos

La descarga de bases de datos se ha realizado desde el Cluster del Instituto de Investigación en Ingeniería de Aragón (I3A), en concreto, en el grupo de investigación BSICoS, utilizando el gestor de descargas wget.

Para la lectura, se ha utilizado la librería `wfdb` de Python, que permite leer los registros ECG y extraer las anotaciones correspondientes. Puesto que el trabajo se centra en la predicción inminente, se han extraído ventanas inmediatamente anteriores a los episodios de fibrilación auricular (Pre-PAF), en concreto, de un máximo de 5 minutos anteriores al episodio, además de segmentos de control de ritmo sinusal estable.

Cada registro se ha cargado en memoria como un array de `NumPy` para su posterior procesamiento.

3.2 Preprocesamiento

El preprocesamiento es esencial por varias razones: las bases de datos utilizadas no presentan la misma frecuencia de muestreo, ni están medidas con el mismo equipo, por tanto hay que implementar un pipeline que unifique las características para que los modelos puedan generalizar correctamente. El pipeline de preprocesamiento consta de tres pasos principales:

1. **Armonización de Canales y Frecuencia de Muestreo:** Se unifican todas las señales a exactamente dos canales y una frecuencia de muestreo de 128 Hz. Si un registro posee menos de dos canales, se realiza un relleno (padding) con ceros; si posee más, se seleccionan únicamente las dos primeras derivaciones. En nuestro caso todas las bases de datos contienen 2 canales, pero se comprueba por generalidad, para tener la posibilidad de añadir posteriormente bases de datos adicionales. El remuestreo se ejecuta mediante interpolación trigonométrica.
2. **Atenuación del Ruido e Interferencia:** La eliminación del ruido remanente se delega en las primeras capas convolucionales del modelo, que aprenden filtros adaptativos optimizados para la tarea.

3. **Normalización Z-score Local:** Para evitar sesgos debido a las variaciones inter-sujeto o inter-dispositivo en la amplitud absoluta de las señales, cada segmento se normaliza de forma independiente por canal en el dataloader aplicando:

$$x_{\text{norm}} = \frac{x - \mu}{\sigma + 10^{-8}}$$

donde μ y σ representan la media y desviación estándar de la amplitud de cada ventana.

3.3 Extracción de Ventanas y Prevención de Data Leakage

El pipeline procesa los registros de manera dinámica para extraer los dos tipos de segmentos requeridos para la clasificación binaria:

- **Clase 1 (Pre-PAF):**

Esta clase corresponde al estado inmediatamente anterior al inicio de un episodio de fibrilación auricular. Para la extracción de las ventanas, se ha optado por extraer ventanas de longitud variable, de entre 10 segundos y 5 minutos (300 segundos) previos al episodio. La ventana retrocede en el tiempo hasta encontrarse con el inicio del registro o el final del episodio arrítmico previo, garantizando que el segmento contenga únicamente ritmo sinusal.

- **Clase 0 (Normal/Control):** Se extraen segmentos estables de ritmo sinusal de 5 minutos de duración, que se encuentren alejados al menos 30 minutos (1800 segundos) de cualquier episodio (tanto antes como después), evitando zonas de transición.

Esto es importante, ya que estamos extrayendo ventanas de clase normal de pacientes tanto con PAF como sanos.

Esta estrategia es fundamental para evitar el sesgo de clasificación inter-sujeto. Si la Clase 0 se compusiera únicamente de individuos sanos, los modelos tenderían a clasificar diferencias morfológicas asociadas a la cardiopatía estructural del paciente (cardiopatía de fondo) en lugar de identificar los cambios transitorios que desencadenan el episodio. Al incluir el ritmo sinusal basal del propio paciente como control, se garantiza que el modelo aprenda a predecir la transición temporal hacia la arritmia.

Para evitar la filtración de datos (*data leakage*), que invalidaría los resultados, los segmentos se agrupan estrictamente por sujeto. Esto garantiza que en validación y test no haya pacientes que ya hayan aparecido en el entrenamiento, ya que el modelo podría aprender a reconocer la morfología de un paciente concreto en lugar de aprender a generalizar la predicción de la fibrilación auricular.

3.4 Aumento de Datos (Data Augmentation)

Debido a que los modelos escalan mejor con grandes cantidades de datos, se ha implementado un pipeline de aumento de datos, que aplica modificaciones realistas a las señales directamente en el dataloader con una probabilidad del 50 % para cada una:

- **Deriva de la Línea de Base (*Baseline Wander*):** Se simula la deriva lenta causada por la respiración del paciente sumando una señal sinusoidal:

$$x_{\text{aug}}(t) = x(t) + A \cdot \sin(2\pi \cdot f \cdot t)$$

donde la frecuencia f se muestrea de manera uniforme en $[0,1, 0,5]$ Hz y la amplitud A en $[0,05, 0,2]$.

- **Ruido Gaussiano Aditivo:** Se simula el ruido instrumental sumando ruido blanco gaussiano con una desviación estándar variable $\sigma_{\text{noise}} \sim U(0,01, 0,05)$.
- **Escalado Aleatorio:** Se multiplica el segmento por un factor de escala $s \sim U(0,85, 1,15)$ para simular fluctuaciones en la ganancia del amplificador.
- **Slice Aleatorio de Ventana:** Dado que las redes se entrenan con ventanas de 10 segundos, y contamos con señales de hasta 5 minutos, se extraen 10 segundos aleatorios. En validación y test, se toma de forma determinista los últimos 10 segundos (el instante más cercano al inicio de la crisis en la Clase 1).

3.5 Extracción de Variabilidad del Ritmo Cardíaco (HRV)

Como información complementaria, se extraen nueve variables clásicas de variabilidad del ritmo cardíaco (HRV) a partir de los intervalos RR (detectados mediante las anotaciones de los picos QRS originales rescalados a 128 Hz):

- **Métricas Temporales:** Media de los intervalos RR (`mean_rr`), desviación estándar de los intervalos RR (`std_rr`), raíz cuadrada de la media de las diferencias al cuadrado de intervalos RR sucesivos (`rmssd`), porcentaje de intervalos sucesivos que difieren en más de 50 ms (`pnn50`), media de la frecuencia cardíaca instantánea (`mean_hr`) y su desviación estándar (`std_hr`).
- **Métricas Frecuenciales:** Energía en baja frecuencia (`lf`, 0,04 – 0,15 Hz), energía en alta frecuencia (`hf`, 0,15 – 0,4 Hz) obtenidas por el método de Welch, y la relación de balance autonómico (`lf_hf_ratio`).

Estas características se normalizan globalmente utilizando la media y desviación estándar del conjunto de entrenamiento de referencia antes de ser introducidas en el modelo.

3.6 Arquitecturas de Aprendizaje Profundo

Se proponen cuatro arquitecturas para procesar la señal de entrada $\mathbf{X} \in \mathbb{R}^{2 \times L}$ (donde $L = 1280$ muestras para una ventana de 10 segundos a 128 Hz):

3.6.1 ResNet 1D (Baseline)

Basada en bloques convolucionales 1D residuales. Cada bloque residual consta de capas convolucionales seguidas de normalización (*Batch Normalization*), activación ReLU y una *skip connection* que suma la entrada original a la salida del bloque, facilitando el flujo del gradiente en arquitecturas profundas.




Figura 3.1: Arquitectura base ResNet 1D. La red procesa la entrada reduciendo progresivamente la dimensión temporal mediante bloques residuales, integrando finalmente las características HRV antes del clasificador *fully connected*.

3.6.2 SEResNet 1D (Atención de Canales)

Añade bloques *Squeeze-and-Excitation* (SE) tras cada bloque residual. El bloque SE comprime la información espacial del canal mediante un *Global Average Pooling* y, a través de una pequeña red *fully connected* con cuello de botella, calcula un peso de excitación para cada canal. Esto permite a la red ponderar la importancia relativa de cada una de las dos derivaciones del ECG de forma dinámica.

3.6.3 CNN-Transformer Híbrido

Combina las fortalezas de las redes convolucionales y los mecanismos de atención. Las capas convolucionales iniciales extraen rasgos morfológicos locales y reducen la dimensión temporal de la secuencia. Posteriormente, el Transformer procesa la secuencia resultante. Utilizando mecanismos de *Multi-Head Self-Attention*, el Transformer captura relaciones de largo alcance y dependencias temporales complejas a lo largo de todo el segmento de ECG.

3.6.4 Mamba 1D (Modelo de Espacio de Estados)

Como alternativa al Transformer, se implementa una arquitectura basada en *State space models* (SSM) de selección variable (Mamba). Mamba parametriza un sistema lineal invariante en el tiempo que procesa la señal a través de una recurrencia lineal selectiva y dependiente de los datos. Esto permite capturar dependencias de largo alcance con una complejidad computacional que escala linealmente $O(L)$ en lugar de cuadrática $O(L^2)$ como ocurre con el Transformer.




Figura 3.2: Arquitectura SEResNet 1D. Tras cada bloque residual se incorpora un módulo Squeeze-and-Excitation que recalibra adaptativamente los pesos de los canales de extracción de características.




Figura 3.3: Arquitectura híbrida CNN-Transformer. Se utiliza un *frontend* convolucional para la extracción local y reducción de dimensionalidad, seguido de codificadores posicionales y un *Transformer Encoder* para la atención global.




Figura 3.4: Arquitectura híbrida CNN-Mamba. La secuencia latente generada por el *frontend* convolucional es procesada de forma puramente secuencial mediante bloques SSM selectivos, prescindiendo de codificadores posicionales.

3.6.5 Integración de Características HRV

Adicionalmente, las nueve variables normalizadas de HRV se introducen en un perceptrón multicapa (MLP) de dos capas en las cabezas clasificatorias. La representación vectorial resultante se concatena con el vector de características morfológicas extraído por la red (ResNet, SEResNet, Transformer o Mamba) a la salida de su capa de promedio global. Finalmente, esta representación combinada se introduce en una capa lineal clasificadora con activación Softmax para emitir la probabilidad de Pre-PAF.

3.7 Estrategia de Evaluación y Validación Cruzada

Dado el fuerte desbalance de clases a favor de la clase Pre-PAF tras el proceso de aumentación, y la heterogeneidad de los datos, el diseño experimental se define mediante:

- **Validación Cruzada (5-Fold GroupKFold):** El dataset total se divide en 5 *folds* de forma que todos los segmentos de un mismo paciente queden en el mismo *fold*. En cada iteración, se entrenan los modelos en 4 *folds* y se validan en el restante.
- **Evaluación Externa:** Para comparar los modelos en igualdad de condiciones con la literatura científica, los modelos se evalúan adicionalmente en el conjunto de prueba independiente de la base de datos afpdb (PAF Prediction Challenge).
- **Métricas de Calidad:** Se evalúa el rendimiento utilizando la sensibilidad (Recall), especificidad, precisión, puntuación F1 macro (F1 Macro), F1 de la clase Pre-PAF (F1 Clase 1) y el área bajo la curva ROC (AUC-ROC).

Capítulo 4

Resultados y Discusión

En este capítulo se presentan y discuten los resultados obtenidos por las cuatro arquitecturas implementadas (ResNet 1D, SEResNet 1D, el modelo híbrido CNN-Transformer y Mamba 1D). El entrenamiento y ajuste se han realizado mediante una estrategia de validación cruzada por grupos (5-Fold Group Cross-Validation), asegurando que los registros de un mismo sujeto nunca se compartan entre los *folds* de entrenamiento y validación. Finalmente, la capacidad de generalización se evalúa sobre un conjunto de prueba (test) independiente que contiene muestras de todas las bases de datos, complementado con la evaluación en el conjunto de test oficial del PhysioNet Challenge.

4.1 Resultados detallados por arquitectura

En esta sección se presentan en detalle los resultados experimentales obtenidos para cada una de las arquitecturas principales, comenzando por el análisis sistemático de las variaciones estructurales de la red ResNet 1D.

4.1.1 Arquitectura ResNet 1D y variaciones estructurales

Para optimizar el rendimiento del clasificador basado en ResNet 1D, se modificó la arquitectura base para parametrizar sus dimensiones clave y evaluar el impacto de las siguientes variables de diseño:

- **Profundidad de la red:** Variación del número de bloques residuales por capa. El baseline original utiliza 8 bloques (configuración [2, 2, 2, 2]), mientras que la variante profunda utiliza 12 bloques ([3, 3, 3, 3]).
- **Ancho de la red:** Modificación del número de canales convolucionales en las capas sucesivas (baseline original: [32, 64, 128, 256] frente a la versión ancha: [64, 128, 256, 512]).
- **Tamaño del kernel:** Comparación del tamaño del kernel en las convoluciones 1D (baseline: 15 muestras, frente a kernels grandes de 23 y pequeños de 7).
- **Profundidad y Estrechez (Deep-Narrow):** Una combinación de mayor profundidad (15 bloques distribuidos como [3, 4, 6, 3]) con un menor número de canales ([24, 48, 96, 192]) para restringir el número total de parámetros de la red y mitigar el sobreajuste.
- **Aumento de Datos (Data Augmentation):** Evaluación de cada una de las arquitecturas anteriores bajo aumentación de datos al vuelo (ruido gaussiano, balanceo de línea base y escalado de señal).

Cuadro 4.1: Resultados comparativos de las variaciones de la arquitectura ResNet 1D con y sin aumento de datos

Configuración ResNet 1D	Augment.	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
ResNet Base	No	0,7547 $\pm$ 0,06	0.72	0.76	50 %
	Sí	0,7615 $\pm$ 0,06	0.81	0.81	50 %
ResNet Profunda (<i>deep</i>)	No	0,7700 $\pm$ 0,05	0.68	0.68	61 %
	Sí	0,7687 $\pm$ 0,06	0.80	0.81	54 %
ResNet Ancha (<i>wide</i>)	No	0,7877 $\pm$ 0,04	0.78	0.79	57 %
	Sí	0,7671 $\pm$ 0,05	0.81	0.81	57 %
ResNet Kernel Grande ($k=23$)	No	0,7594 $\pm$ 0,05	0.81	0.81	57 %
	Sí	0,7533 $\pm$ 0,06	0.81	0.81	57 %
ResNet Kernel Pequeño ($k=7$)	No	0,7684 $\pm$ 0,04	0.77	0.77	57 %
	Sí	0,7406 $\pm$ 0,06	0.81	0.82	46 %
ResNet Profunda y Estrecha	No	0,7573 $\pm$ 0,06	0.79	0.80	64 %
	Sí	0,7596 $\pm$ 0,07	0.80	0.80	68 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado oficial de PhysioNet Challenge (Event 2).

Los resultados cuantitativos obtenidos por cada variante mediante validación cruzada de 5 pliegues por grupos y sobre el conjunto de test independiente se resumen en la Tabla 4.1.

De los resultados de la Tabla 4.1 se extraen los siguientes análisis principales:

1. **La profundidad supera al ancho en generalización externa:** El modelo `resnet1d_deep_narrow` con aumento de datos logró el mejor balance, obteniendo un score de reto del 68 % y manteniendo una exactitud del 80 % en test. A pesar de que la configuración ancha (`resnet1d_wide`) obtuvo el mayor rendimiento de validación local (F1 Macro de 0.7877), su capacidad de generalización sobre el test ciego oficial cayó a 57 %, sugiriendo que un número excesivo de filtros por capa induce un sobreajuste morfológico severo.
2. **Efecto sinérgico del aumento de datos en redes estrechas:** El aumento de datos (ruido gaussiano, escalado de amplitud y balanceo de línea base) actuó como un regularizador muy efectivo en configuraciones estrechas. En `resnet1d_deep_narrow`, el score de reto subió del 64 % al 68 %. Sin embargo, en configuraciones más pesadas (como la ResNet profunda con canales estándar), la aumentación de datos dificultó la convergencia óptima, reduciendo su desempeño en el reto (del 61 % al 54 %).
3. **Sensibilidad a la escala temporal del kernel:** El modelo con kernel pequeño ($k = 7$) entrenado con aumentación sufrió la mayor degradación en el reto oficial (46 %). Con una resolución de muestreo de 128 Hz, un kernel de 7 muestras cubre únicamente 54 ms de señal, lo que impide a la red discernir el contexto del intervalo cardíaco frente a fluctuaciones inducidas por el balanceo de línea base o el ruido gaussiano.

4.1.2 Arquitectura SEResNet 1D con atención de canales

Para evaluar si los mecanismos de atención por canal (Squeeze-and-Excitation, [7]) ofrecen ventajas en combinación con perturbaciones sintéticas de señal, se modificó la arquitectura base para parametrizar sus dimensiones clave y evaluar el impacto de las variables de diseño (profundidad, ancho, tamaño de kernel y la combinación profunda-estrecha) tanto con como sin aumento de datos.

Los resultados de rendimiento obtenidos se detallan en la Tabla 4.2.

Cuadro 4.2: Resultados comparativos de las variaciones de la arquitectura SEResNet 1D con y sin aumento de datos

Configuración SEResNet 1D	Augment.	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
SEResNet Base	No	0,7634 $\pm$ 0,08	0.73	0.73	50 %
	Sí	0,7553 $\pm$ 0,08	0.82	0.83	54 %
SEResNet Profunda	No	0,7726 $\pm$ 0,06	0.83	0.83	61 %
	Sí	0,7523 $\pm$ 0,08	0.80	0.80	57 %
SEResNet Ancha	No	0,7723 $\pm$ 0,07	0.82	0.82	61 %
	Sí	0,7697 $\pm$ 0,08	0.82	0.83	46 %
SEResNet Kernel Grande	No	0,7611 $\pm$ 0,07	0.77	0.78	57 %
	Sí	0,7470 $\pm$ 0,09	0.81	0.82	46 %
SEResNet Kernel Pequeño	No	0,7701 $\pm$ 0,06	0.82	0.83	46 %
	Sí	0,7617 $\pm$ 0,08	0.83	0.83	50 %
SEResNet Profunda y Estrecha	No	0,7568 $\pm$ 0,08	0.73	0.73	57 %
	Sí	0,7593 $\pm$ 0,07	0.80	0.80	68 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado oficial de PhysioNet Challenge (Event 2).

De los resultados de la Tabla 4.2 se desprenden las siguientes observaciones relevantes:

- Efecto sinérgico del aumento de datos en redes estrechas:** Al igual que en la ResNet estándar, la configuración profunda y estrecha (`senet_deep_narrow`) logra la máxima generalización en el reto ciego con un score del 68 % bajo aumento de datos, mientras que cae a un 57 % sin él. Esto confirma que el aumento de datos (ruido gaussiano, balanceo de línea base y escalado) actúa como un regularizador crítico para habilitar la transferencia inter-base de datos en redes de capacidad restringida.
- Inestabilidad de la atención de canales ante el aumento de datos en redes complejas:** Un hallazgo muy revelador es que las variantes de gran capacidad como la ancha (`senet_wide`) y la de kernel grande (`senet_large_kernel`) obtienen mejores puntuaciones de reto sin aumentación de datos (61 % y 57 % respectivamente) que con ella (46 % en ambos casos). Esto confirma que añadir perturbaciones sintéticas de señal en redes de alta capacidad que usan mecanismos Squeeze-and-Excitation dificulta la convergencia adaptativa de los pesos de atención por canal, forzando al modelo a aprender patrones espurios del ruido local que merman la generalización en dominios clínicos externos.
- Rendimiento local e impacto del campo receptivo:** En el dominio local, varias configuraciones logran resultados sobresalientes, destacando la variante profunda sin aumentación y la variante

de kernel pequeño con aumentación, que alcanzan un F1 Macro de 0.83 y una exactitud de 0.83 en el test set local. No obstante, las variantes de kernel pequeño muestran una generalización externa penalizada (46 % y 50 % en el reto), debido a la incapacidad de un campo receptivo temporal estrecho para mitigar el ruido clínico real.

4.1.3 Arquitectura CNN-Transformer Híbrida y variaciones estructurales

Para superar las limitaciones del baseline del modelo híbrido CNN-Transformer, se evaluó el impacto de regularizar el codificador Transformer y restringir su capacidad paramétrica ante ventanas de análisis pequeñas. Se compararon las siguientes variaciones estructurales entrenadas con y sin aumento de datos:

- **Transformer Base:** La arquitectura baseline con $d_{model} = 128$, 4 cabezas de atención ($n_{head} = 4$) y 3 capas de codificación.
- **Transformer Profundo:** Incremento del número de capas del codificador de 3 a 6 para captar relaciones temporales más abstractas.
- **Transformer Ancho:** Aumento de la capacidad del modelo a $d_{model} = 256$, 8 cabezas ($n_{head} = 8$) y dimensión de feedforward a 512.
- **Transformer Dropout Aumentado:** Elevación del factor de abandono (dropout) de 0.2 a 0.4 para mitigar el sobreajuste.
- **Transformer Estrecho (Narrow):** Reducción drástica de parámetros ($d_{model} = 64$, $n_{head} = 2$, feedforward de 128) para forzar un cuello de botella de información que prevenga la memorización.

Los resultados se detallan en la Tabla 4.3.

Cuadro 4.3: Resultados comparativos de las variaciones de la arquitectura CNN-Transformer 1D con y sin aumento de datos

Configuración Transformer 1D	Augment.	F1 Macro Val (CV)	F1 Macro Test	Accuracy Test	Score Reto (Event 2)
Transformer Base	No	0,7600 ± 0,07	0.77	0.77	57 %
	Sí	0,7528 ± 0,08	0.78	0.78	57 %
Transformer Profundo	No	0,7637 ± 0,07	0.77	0.77	61 %
	Sí	0,7546 ± 0,08	0.81	0.81	61 %
Transformer Ancho	No	0,7651 ± 0,07	0.71	0.71	64 %
	Sí	0,7550 ± 0,09	0.81	0.81	54 %
Transformer Dropout Aumentado	No	0,7581 ± 0,08	0.66	0.66	61 %
	Sí	0,7436 ± 0,09	0.79	0.79	64 %
Transformer Estrecho	No	0,7623 ± 0,08	0.70	0.70	61 %
	Sí	0,7487 ± 0,09	0.79	0.79	71 %

Nota: El score del reto representa la evaluación en el conjunto de test blindado oficial de PhysioNet Challenge (Event 2).

De los resultados de la Tabla 4.3 se extraen los siguientes análisis principales:

1. **La compresión dimensional previene el sobreajuste en Attention:** El modelo Transformer Estrecho con aumentación de datos logra la puntuación de generalización externa más alta del estudio con un score del 71% en el reto ciego. Dado que el volumen de datos clínicos es acotado, reducir la dimensión latente ($d_{model} = 64$) y el número de cabezas de atención fuerza a la red a enfocarse exclusivamente en rasgos morfológicos de alta relevancia clínica (como la variabilidad del intervalo R-R o el aplanamiento de ondas P), evitando la memorización del ruido.
2. **Efecto benéfico del aumento de datos en el dominio local:** A diferencia de las convoluciones SE, los mecanismos de autoatención temporal se benefician sistemáticamente de la aumentación de datos al vuelo en todas las configuraciones complejas, elevando el F1 Macro en test local (p. ej., de 0.71 a 0.81 en la versión ancha, y de 0.66 a 0.79 en la versión con dropout elevado). Esto demuestra que las perturbaciones sintéticas dotan al Transformer de la regularización necesaria para estimar las matrices de atención con mayor robustez frente al ruido fisiológico.

4.1.4 Arquitectura Mamba 1D y capacidad de representación

El modelo Mamba 1D, basado en modelos de espacio de estados selectivos (SSM), se evalúa como alternativa recurrente sub-cuadrática frente a las arquitecturas convolucionales y de atención temporal. Su rendimiento óptimo global se detalla y analiza en la comparativa inter-modelo general.

4.2 Evaluación comparativa inter-modelo

El rendimiento de los mejores modelos seleccionados para cada arquitectura se evalúa a través de las métricas: exactitud global (Accuracy), precisión, sensibilidad (Recall) y la puntuación F1 (F1-score) tanto por clase como promedio (Macro F1). Los resultados cuantitativos obtenidos en la validación cruzada por grupos y en el conjunto de prueba independiente se detallan en la Tabla 4.4.

Cuadro 4.4: Resultados comparativos de rendimiento de las mejores variantes de cada arquitectura en validación y test

Modelo	Split	F1 Clase 0	F1 Clase 1	F1 Macro	Accuracy
ResNet 1D (Deep-Narrow, Aug)	Validación (CV)	—	—	$0,7596 \pm 0,07$	$0,7902 \pm 0,06$
	Test	0.78	0.82	0.80	0.80
SENet 1D (Deep-Narrow, Aug)	Validación (CV)	—	—	$0,7593 \pm 0,07$	$0,7821 \pm 0,06$
	Test	0.77	0.82	0.80	0.80
Transformer (Narrow, Aug)	Validación (CV)	—	—	$0,7487 \pm 0,09$	$0,7722 \pm 0,09$
	Test	0.77	0.82	0.79	0.79
Mamba 1D	Validación (CV)	—	—	$0,7138 \pm 0,09$	$0,7350 \pm 0,09$
	Test	0.75	0.74	0.75	0.75

Nota: La Clase 0 corresponde a Ritmo Sinusal (Normal/Distant) y la Clase 1 a la ventana crítica anterior a la Fibrilación Auricular (Pre-PAF).

Analizando los resultados obtenidos en el conjunto de test, se observa que la arquitectura optimizada **ResNet 1D (Deep-Narrow, Aug)** logra posicionarse, junto con su contraparte con atención de canales

SEResNet 1D (Deep-Narrow, Aug), como el modelo más competitivo globalmente en el dominio local, alcanzando ambos una *accuracy* global del 80 % y un F1 Macro del 80 %. En la detección de la clase crítica Pre-PAF (Clase 1), ambos modelos optimizados obtienen un F1-score del 82 %, superando notablemente a Mamba 1D (74 %) y quedando prácticamente empatados con la arquitectura regularizada **Transformer (Narrow, Aug)**, la cual alcanza un F1-score del 82 % en la detección de Clase 1 y un 79 % de F1 Macro.

Por su parte, el modelo **Mamba 1D** se consolida como una arquitectura muy sólida, logrando un F1 Macro del 75 % con un gran equilibrio entre la detección de ritmo normal (F1 de 75 %) y ritmo pre-arrítmico (F1 de 74 %). Esto supera notablemente al baseline original del Transformer, demostrando que los modelos de espacio de estados selectivos ofrecen una excelente relación generalización-capacidad.

4.3 Análisis de resultados y discusión

La comparación de los modelos entrenados revela conclusiones sobre el diseño de redes neuronales para señales biomédicas:

4.3.1 El impacto de la regularización estructural frente a mecanismos de atención

Originalmente, la superioridad del modelo **SENet 1D** sobre el baseline de **ResNet 1D** convencional se atribuía exclusivamente a la recalibración dinámica de derivaciones mediante el bloque de atención por canal (Squeeze-and-Excitation). Al permitir atenuar derivaciones ruidosas y concentrarse en las que contienen firmas biológicas claras de PAF (ondas P aberrantes, variaciones de HRV), la SEResNet base superaba al baseline original de ResNet por un margen de +7 puntos de F1 Macro.

Sin embargo, los experimentos de optimización estructural demuestran que una regularización arquitectónica bien diseñada, como la de la red `resnet1d_deep_narrow_aug` (que incrementa la profundidad a 31 capas convolucionales pero reduce drásticamente el ancho de los canales a un máximo de 192, combinada con aumentaciones de datos al vuelo), puede lograr un rendimiento equivalente (80 % F1 Macro en ambos casos). Esto indica que la constricción de capacidad estructural combinada con perturbaciones sintéticas de señal es una alternativa de regularización sumamente potente que compite directamente con la calibración adaptativa de derivaciones, logrando un rendimiento idéntico.

4.3.2 Superación del Sobreajuste en el CNN-Transformer Híbrido mediante Compresión Dimensional

Aunque originalmente el baseline del CNN-Transformer híbrido sufría de sobreajuste severo debido al elevado número de parámetros de los bloques de atención aplicados sobre ventanas temporales relativamente pequeñas de 10 segundos, los resultados demuestran que la compresión paramétrica resuelve esta limitación de manera drástica. Al constreñir las dimensiones latentes en la variante Transformer Estrecho ($d_{model} = 64$, $n_{head} = 2$, $dim_{feedforward} = 128$), se reduce la complejidad del espacio de búsqueda, lo que permite al codificador del Transformer converger con mayor facilidad y lograr una alta capacidad de generalización. Como consecuencia directa, esta variante alcanza la puntuación más alta en el reto ciego externo (71 % de Event 2 score), demostrando que la regularización por estrechez paramétrica es fundamental para aplicar arquitecturas de atención sobre señales biomédicas con conjuntos

de datos limitados.

4.3.3 Modelos de Espacio de Estados (Mamba 1D) y su Capacidad de Generalización

La arquitectura **Mamba 1D** presenta un rendimiento sólido, obteniendo un F1 Macro del 75 % en el conjunto de test. Esto posiciona a Mamba 1D como una de las mejores arquitecturas en cuanto a generalización global, superando al baseline del CNN-Transformer Híbrido, aunque quedando por detrás de las versiones regularizadas de ResNet, SENet y del Transformer Estrecho. El éxito de Mamba 1D se puede deber a su capacidad de procesar las dependencias temporales a través de un mecanismo de selección recurrente lineal variable que escala linealmente $O(L)$ en lugar de la atención cuadrática $O(L^2)$ del Transformer. Al evitar el sobreajuste masivo que sufren los Transformers en conjuntos de datos medianos, Mamba conserva gran parte de la información de largo alcance sin penalizar su capacidad de generalización en test.

4.3.4 Discrepancia entre el rendimiento en test general y el benchmark de PhysioNet

Un hallazgo clave de este trabajo es la discrepancia observada entre el rendimiento en el conjunto de prueba general y las puntuaciones en el reto oficial de PhysioNet (afpdb):

- Originalmente se fue más estricto a la hora de extraer ventanas, asumiendo que si no se encontraban 5 minutos completos, no se consideraba. Esto dejó a la base de datos afpdb como una fuente altamente representativa, y por ello los modelos obtenían puntuaciones altas en el reto (hasta 79 % en el CNN-Transformer y 75 % en la ResNet 1D), pero a costa de un F1-score muy bajo en condiciones generales (56 % y 61 % respectivamente).
- Tras realizar el aumento de datos mediante ventanas variables, el volumen de la base de datos del reto (afpdb) pasa a representar solo el 1.2 % del total de Clase 1 en el entrenamiento, que ahora es dominado por registros de Holter ambulatorio de 24 horas (1tafdb) y dispositivos corporales inteligentes (shdb-af).
- Como consecuencia directa, la generalización clínica ante nuevos sujetos mejora notablemente (alcanzando el 82 % de F1 Pre-PAF en la ResNet optimizada), pero las puntuaciones del reto específico se sitúan en 71 % para el Transformer estrecho y aumentado, 68 % para la ResNet y SEResNet regularizadas y aumentadas, 54 % para el Mamba 1D y 50 % para la ResNet 1D baseline.

Al optimizar los modelos con un dataset más grande, diverso y realista, las redes aprenden a priorizar rasgos generales de ECG ambulatorio y wearables. Sin embargo, esto diluye la especialización del modelo a la base de datos afpdb original.

4.4 Comparación con trabajos relacionados

La mayoría de los algoritmos publicados en la literatura científica que evalúan su rendimiento en el PhysioNet Challenge de predicción de PAF entrenan y validan sus modelos únicamente utilizando los datos de la base de datos afpdb, o de bases de datos específicas. Aunque muchos logran clasificaciones

sobresalientes en este benchmark específico (79 % de precisión), carecen de la generalidad que ofrecen estos modelos.

Este trabajo demuestra que el entrenamiento exclusivo sobre una única base de datos induce un sesgo de adquisición artificial. Al contrastar nuestros modelos con una validación cruzada inter-sujeto sobre cinco bases de datos, demostramos la viabilidad de un predictor de PAF generalizable capaz de mantener una alta sensibilidad y especificidad incluso en señales capturadas por wearables en condiciones cotidianas.

Capítulo 5

Conclusiones

A continuación, se presentan las conclusiones finales del proyecto planteando las futuras líneas de investigación.

5.1 Resumen y aportaciones del proyecto

Las principales contribuciones incluyen:

- La consolidación de cinco bases de datos heterogéneas (afpdb, cpsc2021, ltafdb, shdb-af y afdB) en un único formato.
- La prevención de filtrado de información (data leakage) aplicando una separación de conjuntos de datos agrupando por paciente.
- La comparación del rendimiento de modelos convolucionales tradicionales frente a arquitecturas residuales avanzadas (SEResNet) con *self-attention* de canales.

5.2 Cumplimiento de objetivos

Se han alcanzado los objetivos iniciales planteados...

5.3 Valoración crítica y limitaciones

A pesar de la alta capacidad de clasificación, el problema presenta desafíos debido a la variabilidad de la señal ECG en diferentes pacientes y el ruido inherente a los dispositivos de registro ambulatorio.

5.4 Líneas futuras

Como extensiones naturales al trabajo realizado, se proponen las siguientes líneas de desarrollo futuro:

- **Exploración de Modelos de Lenguaje para Señales (Signal Transformers):** Investigar arquitecturas avanzadas auto-supervisadas preentrenadas en grandes corpus de datos ECG.
- **Optimización de Hyperparámetros en SEResNet:** Refinar el ratio de reducción en los bloques Squeeze-and-Excitation.
- **Despliegue e integración clínica:** Probar el clasificador en sistemas integrados de monitoreo en tiempo real.

Referencias

- [1] *Atrial fibrillation*, en *Wikipedia*, Page Version ID: 1350567686, 22 de abr. de 2026. dirección: https://en.wikipedia.org/w/index.php?title=Atrial_fibrillation&oldid=1350567686
- [2] G. B. Moody, A. L. Goldberger, S. McClennen y S. P. Swiryn, *PAF Prediction Challenge Database*, 2001. DOI: [10.13026/C2H59W](https://doi.org/10.13026/C2H59W) dirección: <https://physionet.org/content/afpdb/>
- [3] X. Wang, C. Ma, X. Zhang, H. Gao, G. D. Clifford y C. Liu, "Paroxysmal Atrial Fibrillation Events Detection from Dynamic ECG Recordings: The 4th China Physiological Signal Challenge 2021", *PhysioNet*, jun. de 2021, Version 1.0.0. DOI: [10.13026/ksya-qw89](https://doi.org/10.13026/ksya-qw89) dirección: <https://doi.org/10.13026/ksya-qw89>
- [4] S. Petrutiu, A. V. Sahakian y S. Swiryn, *The Long-Term AF Database*, 2003. DOI: [10.13026/C2QG6Q](https://doi.org/10.13026/C2QG6Q) dirección: <https://physionet.org/content/ltafdb/>
- [5] K. Tsutsui, S. Biton Brimer y J. Behar, "SHDB-AF: a Japanese Holter ECG database of atrial fibrillation", *PhysioNet*, abr. de 2025, Version 1.0.1. DOI: [10.13026/n6yq-fq90](https://doi.org/10.13026/n6yq-fq90) dirección: <https://doi.org/10.13026/n6yq-fq90>
- [6] G. B. Moody y R. G. Mark, *MIT-BIH Atrial Fibrillation Database*, 1992. DOI: [10.13026/C2MW2D](https://doi.org/10.13026/C2MW2D) dirección: <https://physionet.org/content/afdb/>
- [7] J. Hu, L. Shen y G. Sun, "Squeeze-and-Excitation Networks", en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, jun. de 2018, págs. 7132-7141. DOI: [10.1109/CVPR.2018.00745](https://doi.org/10.1109/CVPR.2018.00745)

Anexos